

แบบเสนอโครงงานนักศึกษา

ข้อเสนอโครงงานฉบับสมบูรณ์ (Full proposal)

ชื่อโครงงาน (ภาษาไทย) : ระบบ

ชื่อโครงงาน (ภาษาอังกฤษ) : Facial Deepfake Video Detection System Using Artificial Intelligence

จัดทำโดย

- นายคุณานนท์ สารีมา รหัสนักศึกษา 67040233141
หลักสูตร เทคโนโลยีสารสนเทศ

อาจารย์ที่ปรึกษาโครงงาน : รศ.ดร.กริช สมกันธา

ภาคการศึกษาที่ 1 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์และเทคโนโลยีสารสนเทศ

คณะวิทยาศาสตร์

มหาวิทยาลัยราชภัฏอุดรธานี

บทที่ 1

บทนำ

1.1 หลักการและเหตุผล

ปัจจุบันเทคโนโลยีปัญญาประดิษฐ์และการเรียนรู้ของเครื่อง มีการพัฒนาอย่างก้าวกระโดด โดยเฉพาะเทคโนโลยีการสร้างเนื้อหาจำลองที่สามารถผลิตสื่อปลอมที่มีความสมจริงสูง หนึ่งในเทคโนโลยีที่สร้างผลกระทบอย่างมากในปัจจุบันคือ Deepfake ซึ่งเป็นเทคนิคเชิงลึกที่สามารถปลอมแปลงใบหน้าและการแสดงสีหน้าของบุคคลในวิดีโอได้อย่างแนบเนียน การเข้าถึงเครื่องมือสร้างวิดีโอ Deepfake ที่เปิดกว้างและใช้งานง่ายขึ้น ทำให้เกิดการนำไปใช้ในทางที่ผิดอย่างแพร่หลาย เช่น การสร้างข่าวปลอมเพื่อบิดเบือนข้อเท็จจริงทางสังคม การหลอกลวงต้มตุ๋นทางออนไลน์ การข้ามผ่านระบบยืนยันตัวตนทางดิจิทัล ตลอดจนการสร้างสื่อที่ละเมิดสิทธิส่วนบุคคล ซึ่งสร้างความเสียหายทั้งต่อทรัพย์สิน ชื่อเสียง และความมั่นคงของระบบสารสนเทศโดยรวม

จากรายงานและบทความทางวิชาการที่เกี่ยวข้อง พบว่าการตรวจจับและแยกแยะวิดีโอ Deepfake ด้วยสายตาเปล่าเป็นเรื่องที่ท้าทายมากขึ้นสำหรับมนุษย์ ในอดีตแนวทางการสังเกตด้วยตนเอง เช่น การพิจารณาอัตราการกะพริบตา การขยับปากที่ไม่สัมพันธ์กับเสียง ความผิดปกติของแสงเงา หรือรอยต่อบริเวณกรอบหน้า อาจเคยใช้เป็นจุดสังเกตได้ดี แต่ในปัจจุบันอัลกอริทึมในการทำ Deepfake ถูกพัฒนาให้สามารถกลบร่องรอยและปรับความสมจริงได้อย่างแนบเนียนยิ่งขึ้น ทำให้การพึ่งพาเพียงการสังเกตด้วยสายตาอาจไม่เพียงพอและมีความเสี่ยงที่จะคลาดเคลื่อนได้เมื่อต้องเผชิญกับสื่อปลอมแปลงระดับสูง

ด้วยเหตุนี้ การประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์และการเรียนรู้เชิงลึก เพื่อเข้ามาช่วยตรวจสอบและต่อสู้กับปัญญาประดิษฐ์ด้วยกันเองจึงเป็นสิ่งจำเป็น โครงการนี้จึงมีแนวคิดในการพัฒนาระบบตรวจจับวิดีโอ Deepfake โดยอาศัยสถาปัตยกรรม Xception เพื่อสกัดคุณลักษณะและค้นหาร่องรอยการปลอมแปลงในระดับพิกเซลที่สายตามนุษย์มองไม่เห็น โดยพัฒนาให้อยู่ในรูปแบบของเว็บแอปพลิเคชัน เพื่อให้ง่ายต่อการเข้าถึงและใช้งาน ระบบดังกล่าวจะทำหน้าที่เป็นเครื่องมือสนับสนุนการประเมินความน่าเชื่อถือของสื่อวิดีโอเบื้องต้น ช่วยลดความเสี่ยงจากการตกเป็นเหยื่อของการหลอกลวง และยกระดับความปลอดภัยในการบริโภคข้อมูลข่าวสารดิจิทัลในสังคมยุคปัจจุบัน

1.2 วัตถุประสงค์

1. เพื่อพัฒนาระบบตรวจจับวิดีโอที่ผิดปกติบนหน้าด้วยปัญญาประดิษฐ์

1.3 ขอบเขตของการศึกษา

1.3.1 ระบบ

- 1.3.1.1 ระบบสามารถจำแนกวิดีโอที่มีใบหน้าบุคคลได้ 5 แบบ ได้แก่

- 1) วิดีโอจริง
- 2) Deepfakes
- 3) Face2Face
- 4) FaceShifter
- 5) NeuralTextures

- 1.3.1.2 ระบบใช้เทคนิค Extreme Inception (Xception) ในการวิเคราะห์และจำแนกวิดีโอ

- 1.3.1.3 สามารถแสดงผลของการจำแนกวิดีโอได้

- 1.3.1.4 ระบบทำงานผ่านเว็บแอปพลิเคชัน

- 1.3.1.5 ระบบรองรับการอัปโหลดไฟล์วิดีโอนามสกุล mp4, .avi, .mov ความยาว 5-60 วินาที และขนาดไฟล์ไม่เกิน 120 MB ต่อไฟล์

- 1.3.1.6 ระบบรองรับวิดีโอที่มีความละเอียดระหว่าง 480p ถึง 1080p

1.3.2 ผู้ดูแลระบบ

- 1.3.2.1 สามารถเข้าสู่ระบบและออกจากระบบได้

- 1.3.2.2 สามารถดูสถิติและภาพรวมการใช้งานของระบบ ได้แก่

- 1) จำนวนวิดีโอที่ผู้ใช้ทั่วไปอัปโหลดเข้ามาทั้งหมด
- 2) จำนวนผลลัพธ์ที่ระบบจำแนกได้ว่าเป็นวิดีโอจริงหรือวิดีโอปลอมแปลง
- 3) ประวัติการตรวจจับวิดีโอย้อนหลังของระบบ

- 1.3.2.3 สามารถเพิ่ม และลบโมเดลที่ใช้ในการจำแนกได้

- 1.3.2.4 สามารถเปิด-ปิดการใช้งานโมเดลได้

1.3.3 ผู้ใช้ทั่วไป

1.3.3.1 สามารถอัปโหลดไฟล์วิดีโอที่มีใบหน้าบุคคลเพื่อทำการจำแนกได้

1.3.3.2 สามารถดูผลลัพธ์การจำแนกวิดีโอได้ ซึ่งประกอบด้วย

- 1) เป็นวิดีโอจริงหรือวิดีโอปลอมแปลง
- 2) ประเภทของดีปเฟก
- 3) ค่าความเชื่อมั่นของผลการจำแนก

1.3.4 ชุดข้อมูลที่ใช้

1.3.4.1 ใช้ข้อมูลจากชุดข้อมูล FaceForensics++ (c23) โดยคัดเลือกมาใช้จำนวน 5,000 วิดีโอ

1.3.4.2 ชุดข้อมูลถูกแบ่งออกเป็น

- 1) Training Set ร้อยละ 70
- 2) Validation Set ร้อยละ 15
- 3) Test Set ร้อยละ 15

1.3.5 การประเมินผล

1.3.5.1 ประเมินประสิทธิภาพของโมเดลด้วยตัวชี้วัด ได้แก่

- 1) Confusion Matrix
- 2) Accuracy
- 3) Precision
- 4) Recall
- 5) F1-score

1.4 ข้อจำกัดของการศึกษา

1.4.1 ระบบรองรับเฉพาะใบหน้าที่มองเห็นชัดเจน

1.4.2 หากใบหน้ามีการบังหรือแสงน้อย ประสิทธิภาพอาจลดลง

1.4.3 ระบบออกแบบมาสำหรับวิดีโอที่มีใบหน้าบุคคลหลักเพียงคนเดียวในเฟรมและมองเห็นได้ชัดเจน

บทที่ 2

วรรณกรรมและงานวิจัยที่เกี่ยวข้อง

2.1 ความรู้พื้นฐานเกี่ยวกับระบบงาน


2.1.1 เทคโนโลยีดีปเฟก (Deepfake Technology)

เทคโนโลยีดีปเฟก (Deepfake Technology) นับเป็นนวัตกรรมที่ผสมผสานความก้าวหน้าของปัญญาประดิษฐ์ (Artificial Intelligence) และการเรียนรู้เชิงลึก (Deep Learning) เข้าด้วยกัน เพื่อสังเคราะห์และปรับแต่งสื่อมัลติมีเดียให้มีความสมจริงอย่างแนบเนียน จนบางครั้งอาจยากเกินกว่าที่สายตามนุษย์จะสังเกตเห็นความผิดปกติได้ กระบวนการดังกล่าวอาศัยสถาปัตยกรรมโครงข่ายประสาทเทียมในการเรียนรู้จากชุดข้อมูลภาพหรือวิดีโอจำนวนมาก เพื่อทำความเข้าใจโครงสร้างทางกายภาพ การแสดงออกทางสีหน้า และรูปแบบการเคลื่อนไหวของบุคคลเป้าหมาย ก่อนนำมาใช้สร้างสรรค์สื่อจำลองในลักษณะต่าง ๆ โดยเฉพาะกระบวนการสลับใบหน้า (Face Swapping) และการควบคุมการแสดงสีหน้า (Facial Reenactment) โดยประเภทของเทคโนโลยีดีปเฟกที่นำมาใช้ในการศึกษา มีรายละเอียดดังนี้



รูปที่ 2.1 ตัวอย่างกระบวนการสลับใบหน้าด้วยเทคนิคดีปเฟก [1]

2.1.1.1 Deepfakes: เป็นเทคนิคการสลับใบหน้า (Face Swapping) ที่มักสร้างขึ้นโดยใช้โครงข่ายประสาทเทียมประเภทอโตเอนคอดเดอร์ (Autoencoders) หรือ Generative Adversarial Networks (GANs) เพื่อนำใบหน้าของบุคคลหนึ่งไปแทนที่ใบหน้าของอีกบุคคลหนึ่งในวิดีโอต้นฉบับ โดยอาศัยการเรียนรู้โครงสร้างลักษณะหน้าและมุมมองแสงเงาเพื่อให้เกิดความกลมกลืน




รูปที่ 2.2 ขั้นตอนการทำงานทั่วไปของกระบวนการสลับใบหน้าด้วยเทคนิค Deepfakes [2]

2.1.1.2 Face2Face: เป็นเทคนิคการปลอมแปลงแบบควบคุมการแสดงสีหน้า (Facial Reenactment) โดยอาศัยวิธีการกราฟิกและคอมพิวเตอร์วิทัศน์ในการขับเคลื่อนสีหน้าและท่าทางการขยับปากของบุคคลเป้าหมายในวิดีโอ ให้ดำเนินตามการเคลื่อนไหวของใบหน้าผู้แสดงต้นทางแบบเรียลไทม์โดยไม่มีการเปลี่ยนตัวบุคคล




รูปที่ 2.3 ตัวอย่างการควบคุมการแสดงสีหน้าด้วยเทคนิค Face2Face [3]

2.1.1.3 FaceShifter: เป็นเทคนิคขั้นสูงในการสลับใบหน้าซึ่งถูกพัฒนาขึ้นเพื่อแก้ปัญหาการบิดเบี้ยวของใบหน้าในมุมมองที่ยากหรือมีการบังบางส่วน (Occlusion) โดยใช้กระบวนการเรียนรู้เชิงลึกแบบสองขั้นตอน (Heuristic Error-aware Refinement) ที่ช่วยรักษาความคมชัดและรายละเอียดของสีหน้า ทรงผม และสภาพแสงให้มีความสมจริงสูงขึ้น



รูปที่ 2.4 ตัวอย่างผลลัพธ์การสลับใบหน้าด้วยเทคนิค FaceShifter [4]

2.1.1.4 NeuralTextures: เป็นเทคนิคการสังเคราะห์ความเปลี่ยนแปลงบนพื้นผิวใบหน้าโดยใช้กราฟิกที่ขับเคลื่อนด้วยเครือข่ายประสาทเทียม (Neural Rendering) มักใช้ในการแก้ไขหรือปรับเปลี่ยนการเคลื่อนไหวของริมฝีปากให้สอดคล้องกับเสียงพูดใหม่ที่ถูกใส่เข้ามา (Lip-syncing) โดยการสร้างพื้นผิวรายละเอียดระดับพิกเซลขึ้นมาใหม่ให้แนบเนียนไปกับวิดีโอเดิม




รูปที่ 2.5 ตัวอย่างการปรับเปลี่ยนพื้นผิวใบหน้าด้วยเทคนิค Neural Rendering แบบ NeuralTextures [5]

แม้ว่าเทคโนโลยีเหล่านี้จะมีประโยชน์ต่ออุตสาหกรรมบันเทิงและการผลิตสื่อสร้างสรรค์ แต่การแพร่หลายของเครื่องมือที่เข้าถึงได้ง่ายก็เปิดช่องให้เกิดการนำไปใช้ในทางที่ไม่เหมาะสม เช่น การบิดเบือนข้อเท็จจริงผ่านข่าวปลอม การหลอกลวงเพื่อผลประโยชน์ หรือการล่วงละเมิดสิทธิส่วนบุคคล ซึ่งส่งผลกระทบต่อความน่าเชื่อถือของข้อมูลดิจิทัลโดยรวม ด้วยเหตุนี้ การพัฒนาอัลกอริทึมสำหรับตรวจสอบและจำแนกสื่อปลอมแปลงเหล่านี้จึงกลายเป็นสิ่งสำคัญและมีความจำเป็นอย่างยิ่งในปัจจุบัน

2.1.2 การตรวจจับวิดีโอปลอมแปลงและการประมวลผลภาพเคลื่อนไหว

การตรวจจับวิดีโอปลอมแปลงและการประมวลผลภาพเคลื่อนไหว เป็นกระบวนการวิเคราะห์สื่อวิดีโอเพื่อแยกแยะวิดีโอจริงออกจากวิดีโอที่ถูกปลอมแปลง โดยเฉพาะกรณีดีปเฟกที่มีการเปลี่ยนใบหน้าและสีหน้าของบุคคลให้ดูสมจริงใกล้เคียงกับต้นฉบับจนแทบแยกไม่ออกด้วยสายตาเปล่า ระบบตรวจจับสมัยใหม่จึงอาศัยเทคโนโลยีประมวลผลภาพเคลื่อนไหวร่วมกับโครงข่ายประสาทเทียมเชิงลึก เพื่อสกัดคุณลักษณะจากเฟรมวิดีโอหลาย ๆ เฟรมและค้นหาร่องรอยความผิดปกติในระดับพิกเซล เช่น การบิดเบี้ยวของพื้นผิวใบหน้า การเปลี่ยนแปลงของแสงเงาที่ไม่สัมพันธ์กับฉาก หรือการเคลื่อนไหวที่ไม่สอดคล้องกันระหว่างใบหน้าและส่วนอื่นของร่างกาย

ในการประมวลผลภาพเคลื่อนไหว ระบบจะรับไฟล์วิดีโอที่มีใบหน้าบุคคล จากนั้นแยกเฟรมวิดีโอและดึงบริเวณใบหน้าด้วยโมดูลตรวจจับใบหน้า ก่อนนำภาพที่ได้เข้าโมเดลเรียนรู้เชิงลึกเพื่อจำแนกว่าเป็นวิดีโอจริงหรือวิดีโอปลอมแปลงโดยอัตโนมัติ การกำหนดช่วงความยาววิดีโอ ความละเอียด และขนาดไฟล์ที่รองรับ ช่วยควบคุมเวลาในการประมวลผลและรักษาประสิทธิภาพของระบบให้ตอบสนองได้รวดเร็วบนเว็บแอปพลิเคชันที่ผู้ใช้สามารถอัปโหลดไฟล์และดูผลการจำแนกได้ทันที



รูปที่ 2.6 ขั้นตอนการประมวลผลทั่วไปในการตรวจจับวิดีโอดีปเฟก [6]

2.1.3 ลักษณะใบหน้ามนุษย์จริงในวิดีโอ

ก่อนที่จะเข้าใจวิธีการตรวจจับวิดีโอดีปเฟก จำเป็นต้องเข้าใจก่อนว่าใบหน้าของมนุษย์จริงที่ปรากฏในวิดีโอมีลักษณะทางกายภาพและพฤติกรรมอย่างไร เนื่องจากร่องรอยความผิดปกติที่ใช้ในการตรวจจับดีปเฟกส่วนใหญ่เกิดจากความแตกต่างระหว่างลักษณะที่โมเดลสร้างขึ้นกับลักษณะตามธรรมชาติของใบหน้าคนจริง ซึ่งมีรายละเอียดสำคัญดังนี้

2.1.3.1 พื้นผิวและรายละเอียดระดับผิวหน้า ใบหน้าคนจริงจะมีพื้นผิวที่ประกอบด้วยรายละเอียดขนาดเล็กจำนวนมาก เช่น รูขุมขน เส้นขน ริ้วรอย และความไม่สม่ำเสมอของสีผิวเล็กน้อยที่กระจายอย่างเป็นธรรมชาติทั่วใบหน้า ความละเอียดเหล่านี้มักปรากฏสม่ำเสมอทั้งบริเวณใบหน้า คอ และหู

2.1.3.2 การกะพริบตาและความชื้นของดวงตา โดยเฉลี่ยมนุษย์จะกะพริบตาประมาณ 15–20 ครั้งต่อนาที ในจังหวะที่ไม่สม่ำเสมอแต่เป็นธรรมชาติ ดวงตาของคนจริงยังมีความชื้นที่ทำให้เกิดแสงสะท้อนเป็นประกาย และแสงสะท้อนในลูกตาทั้งสองข้างจะมีตำแหน่งและทิศทางสอดคล้องกัน เนื่องจากสะท้อนแหล่งกำเนิดแสงเดียวกันตามหลักฟิสิกส์

2.1.3.3 แสงเงาและเงาตกกระทบ บนใบหน้าคนจริง ทิศทางของแสงและเงาที่ ตกกระทบบริเวณต่าง ๆ เช่น เบ้าตา สันจมูก และใต้คาง จะสอดคล้องกับทิศทางของแหล่งกำเนิด แสง ในฉากอย่างเป็นเหตุเป็นผลตามหลักฟิสิกส์ของแสง และมีความกลมกลืนกับแสงเงาที่ตกกระทบ วัตถุอื่นในพื้นหลัง

2.1.3.4 การเคลื่อนไหวและอารมณ์บนใบหน้า ใบหน้าคนจริงจะมีการเคลื่อนไหวของกล้ามเนื้อใบหน้าที่ละเอียดอ่อนและต่อเนื่อง (Micro-expressions) เช่น รอยยิ้มที่แท้จริงจะทำให้เกิดริ้วรอยรอบดวงตา การขยับริมฝีปากจะสัมพันธ์กับเสียงพูดอย่างเป็นธรรมชาติ และการเคลื่อนไหวของศีรษะ ใบหน้า และร่างกายส่วนอื่นจะมีความต่อเนื่องกลมกลืนกันตลอดทั้งเฟรมวิดีโอ




รูปที่ 2.7 ลักษณะใบหน้าที่มนุษย์จริง [7]

2.2 วรรณกรรมที่ใช้ในการพัฒนาระบบ

2.2.1 การเรียนรู้ของเครื่อง (Machine Learning)

การเรียนรู้ของเครื่อง (Machine Learning) เป็นแขนงย่อยที่สำคัญของปัญญาประดิษฐ์ ซึ่งมุ่งเน้นไปที่การศึกษาและพัฒนาอัลกอริทึมที่ช่วยให้ระบบคอมพิวเตอร์สามารถเรียนรู้และพัฒนาความสามารถได้ด้วยตนเองจากชุดข้อมูล โดยไม่ต้องพึ่งพาการเขียนโปรแกรมเพื่อสั่งการอย่างเฉพาะเจาะจงในทุกขั้นตอน หลักการทำงานพื้นฐานคือการป้อนข้อมูลตัวอย่างจำนวนมากเข้าสู่ระบบเพื่อให้อัลกอริทึมสร้างโมเดลทางคณิตศาสตร์ที่สามารถค้นหารูปแบบ ความสัมพันธ์ หรือลักษณะเด่นที่ซ่อนอยู่ในข้อมูลเหล่านั้น ส่งผลให้ระบบสามารถทำการทำนายหรือตัดสินใจเมื่อเผชิญกับข้อมูลใหม่ที่ไม่เคยพบเห็นมาก่อนได้อย่างแม่นยำ กระบวนการเรียนรู้ของเครื่องนี้เป็นกลไกสำคัญที่ขับเคลื่อนระบบอัตโนมัติอัจฉริยะในหลากหลายอุตสาหกรรม รวมถึงการประยุกต์ใช้เพื่อวิเคราะห์และจำแนกข้อมูลที่มีความซับซ้อน



รูปที่ 2.8 ประเภทของ Machine Learning [8]

การเรียนรู้แบบมีผู้สอน (Supervised Learning) เป็นรูปแบบการเรียนรู้ของเครื่องที่โมเดลจะถูกฝึกฝนด้วยชุดข้อมูลที่มีการระบุผลลัพธ์หรือเฉลยไว้ล่วงหน้าอย่างชัดเจน กระบวนการนี้เปรียบเสมือนการมีผู้สอนที่คอยบอกระบบว่าข้อมูลนำเข้าแต่ละตัวคืออะไร โดยชุดข้อมูลจะประกอบไปด้วยคุณลักษณะและเป้าหมายที่ต้องการให้ระบบทำนาย เมื่อโมเดลได้รับการฝึกฝนจนสามารถจับคู่ความสัมพันธ์ระหว่างคุณลักษณะและผลลัพธ์ได้อย่างถูกต้องแล้ว ระบบจะสามารถนำความรู้ที่ได้ไปใช้ทำนายผลลัพธ์ของข้อมูลชุดใหม่ที่ยังไม่เคยมีเฉลยมามาก่อน เทคนิคนี้มักถูกนำไปใช้งานประเภทการจำแนกหมวดหมู่ เช่น การแยกแยะรูปภาพใบหน้า หรือการวิเคราะห์การถดถอยเพื่อทำนายค่าตัวเลขต่อเนื่อง


การเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) เป็นแนวทางการฝึกฝนโมเดลด้วยชุดข้อมูลที่ไม่มีการระบุผลลัพธ์หรือไม่มีเฉลยเตรียมไว้ให้ ระบบจะต้องทำหน้าที่สำรวจและทำความเข้าใจโครงสร้างของข้อมูลด้วยตนเอง โดยอัลกอริทึมจะพยายามค้นหารูปแบบ ความคล้ายคลึง หรือความสัมพันธ์ที่ซ่อนอยู่ภายในกลุ่มข้อมูลนั้นแล้วทำการจัดระเบียบใหม่ เทคนิคที่ได้รับความนิยมในกลุ่มนี้คือการจัดกลุ่มข้อมูล ซึ่งเป็นการรวมข้อมูลที่มีลักษณะใกล้เคียงกันไว้เป็นกลุ่มเดียวกัน และการลดทอนมิติข้อมูลเพื่อลดความซับซ้อนของตัวแปรในชุดข้อมูล การเรียนรู้รูปแบบนี้มีประโยชน์อย่างมากในการค้นพบข้อมูลเชิงลึกใหม่ ๆ ที่ซ่อนอยู่ภายในกลุ่มข้อมูลขนาดใหญ่

การเรียนรู้แบบเสริมกำลัง (Reinforcement Learning) เป็นรูปแบบการเรียนรู้ที่จำลองมาจากพฤติกรรมลองผิดลองถูก โดยมีองค์ประกอบหลักคือตัวแทนที่ต้องโต้ตอบกับสภาพแวดล้อมเพื่อเรียนรู้วิธีการตัดสินใจหรือทำตามลำดับขั้นตอนให้บรรลุเป้าหมายที่กำหนด ระบบจะไม่มีข้อมูลเฉลยคอยบอกว่าขั้นตอนใดถูกต้อง แต่ตัวแทนจะได้รับผลตอบกลับในรูปแบบของรางวัลเมื่อกระทำสิ่งที่ เป็นประโยชน์ และบทลงโทษเมื่อกระทำสิ่งที่ผิดพลาด เป้าหมายหลักของอัลกอริทึมคือการค้นหา นโยบายหรือรูปแบบการกระทำที่ช่วยให้ตัวแทนได้รับรางวัลสะสมรวมสูงสุดในระยะยาว เทคนิคนี้ถูกนำไปใช้อย่างแพร่หลายในการพัฒนาระบบที่ต้องอาศัยการตัดสินใจเชิงลำดับขั้นตอน เช่น การควบคุมหุ่นยนต์ หรือการพัฒนาปัญญาประดิษฐ์สำหรับเล่นเกมที่มีความซับซ้อน

2.2.2 การเรียนรู้เชิงลึก (Deep Learning)

การเรียนรู้เชิงลึก (Deep Learning) เป็นแขนงขั้นสูงของการเรียนรู้ของเครื่อง (Machine Learning) ที่ถูกออกแบบมาเพื่อจำลองการทำงานของโครงข่ายเซลล์ประสาทในสมองมนุษย์ (Artificial Neural Networks) สถาปัตยกรรมหลักของเทคโนโลยีนี้คือการสร้างโครงข่ายประสาทที่ซ่อนทับกันหลายชั้น (Multiple Hidden Layers) เพื่อให้ระบบสามารถประมวลผลข้อมูลที่มีความซับซ้อนสูงได้อย่างมีประสิทธิภาพ การเรียนรู้เชิงลึกจึงกลายเป็นเทคโนโลยีแกนหลักที่อยู่เบื้องหลังความสำเร็จของปัญญาประดิษฐ์ในปัจจุบัน ไม่ว่าจะเป็นการประมวลผลภาษาธรรมชาติ การมองเห็นของคอมพิวเตอร์ หรือการวิเคราะห์สื่อสังคมมีเดียขั้นสูง

จุดเด่นสำคัญที่ทำให้การเรียนรู้เชิงลึกแตกต่างจากการเรียนรู้ของเครื่องแบบดั้งเดิม คือความสามารถในการเรียนรู้และสกัดคุณลักษณะเด่น (Feature Extraction) จากข้อมูลดิบจำนวนมากได้อย่างอัตโนมัติ โดยไม่ต้องอาศัยมนุษย์ในการกำหนดรูปแบบหรือคุณลักษณะเฉพาะให้ ระบบสามารถทำความเข้าใจและแยกแยะข้อมูลที่ไม่มีโครงสร้างชัดเจน เช่น ภาพ เสียง หรือวิดีโอ ในระดับที่ลึกซึ้ง ซึ่งมีความสำคัญอย่างยิ่งต่อการนำไปประยุกต์ใช้ในงานที่ต้องการความแม่นยำสูง เช่น การค้นหาร่องรอยความผิดปกติระดับพิกเซลเพื่อจำแนกวิดีโอปลอมแปลง



รูปที่ 2.9 แสดงโครงสร้างของการเรียนรู้เชิงลึก [9]

กระบวนการทำงานของโครงข่ายประสาทเทียมในการเรียนรู้เชิงลึก มีขั้นตอนหลักดังนี้:

2.2.2.1 ชั้นข้อมูลเข้า (Input Layer): ทำหน้าที่รับข้อมูลดิบเข้าสู่ระบบ เช่น ข้อมูลพิกเซลของภาพหรือเฟรมวิดีโอ โดยข้อมูลจะถูกแปลงให้อยู่ในรูปแบบของตัวเลขหรือเมทริกซ์เพื่อให้คอมพิวเตอร์สามารถนำไปคำนวณต่อได้

2.2.2.2 ชั้นซ่อนเร้น (Hidden Layers): เป็นชั้นที่อยู่ระหว่างชั้นข้อมูลเข้าและชั้นผลลัพธ์ โดยมักจะมีหลายชั้นซ่อนทับกัน ทำหน้าที่คำนวณและสกัดคุณลักษณะที่ซ่อนอยู่ในข้อมูล ข้อมูลที่ส่งผ่านแต่ละชั้นจะถูกคัดกรองรายละเอียดที่ซับซ้อนและลึกซึ้งขึ้นเรื่อย ๆ


2.2.2.3 ชั้นผลลัพธ์ (Output Layer): ทำหน้าที่รวบรวมข้อมูลที่ผ่านการประมวลผลจากชั้นซ่อนเร้นทั้งหมด เพื่อคำนวณหาความน่าจะเป็นและแสดงผลการจำแนกประเภท หรือการตัดสินใจขั้นสุดท้ายของโมเดล

2.2.2.4 การปรับปรุงและเรียนรู้ (Optimization): ในระหว่างการฝึกฝนระบบจะทำการเปรียบเทียบผลลัพธ์ที่ทำนายได้กับผลลัพธ์จริงที่ถูกต้อง หากเกิดความคลาดเคลื่อน ระบบจะใช้อัลกอริทึมการแพร่ย้อนกลับ (Backpropagation) เพื่อปรับปรุงค่าน้ำหนัก (Weights) ภายในโครงข่ายเพื่อลดค่าความผิดพลาดสะสมให้เหลือน้อยที่สุด

2.2.3 เครือข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network)

เครือข่ายประสาทเทียมแบบคอนโวลูชัน เป็นอัลกอริทึมการเรียนรู้เชิงลึกที่เหมาะสมกับงานวิเคราะห์ภาพ โครงสร้างของเครือข่ายจะประกอบด้วยเลเยอร์ที่สามารถตรวจจับลักษณะเฉพาะ เช่น รูปร่าง เส้น และลายพื้นผิว โดยมีการสร้างโครงข่ายของชั้นที่ประมวลผลข้อมูลโดยการคอนโวลูชัน และการกำหนดค่าน้ำหนัก (Weight) ในแต่ละชั้นเพื่อจำลองลักษณะพิเศษของข้อมูล รวมถึงมีชั้นที่

ช่วยลดขนาดข้อมูลด้วยการสกัดข้อมูลสำคัญ (Feature Learning Layers) เพื่อนำไปใช้ในการจำแนก แยกหมวดหมู่ข้อมูล สถาปัตยกรรมของเครือข่ายประสาทเทียมแบบคอนโวลูชัน แบ่งตามลักษณะของ ชั้นออกเป็น 5 ประเภทหลัก ดังนี้



รูปที่ 2.10 แสดงโครงสร้างของเครือข่ายประสาทเทียมแบบคอนโวลูชัน [10]

2.2.3.1 ชั้นคอนโวลูชัน (Convolution Layer) เป็นชั้นที่มีการทำ Convolution โดยการคำนวณทางคณิตศาสตร์แบบ Dot Product ของพื้นที่ส่วนย่อยของภาพ (Input) กับเคอร์เนล (Kernel) ซึ่งเคอร์เนลคือเมทริกซ์ขนาดเล็กที่มีขนาดเท่ากับพื้นที่ส่วนย่อยของภาพ ทำหน้าที่เป็นตัวกรองที่จะดึงเอาคุณลักษณะเฉพาะบางอย่างออกมา เช่น ขอบ เส้น หรือความคมชัด เพื่อให้ได้ Output ที่เป็นคุณลักษณะหลักของข้อมูล (Feature Map) สำหรับสมการเอาต์พุตตำแหน่ง (i, j) ของแผนที่

คุณลักษณะช่อง m คือ

$$Y_{i,j,m} = \sum_{c=1}^{C_{in}} \sum_{u=1}^K \sum_{v=1}^K W_{u,v,c,m} \cdot X_{i+u-1,j+v-1,c} + b_m$$


ในส่วนของการคำนวณขนาดเอาต์พุตจะใช้สมการ

$$H_{out} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1$$

และ

$$W_{out} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1$$

โดยที่ H, W คือขนาดอินพุต, S คือระยะเลื่อน (Stride), P คือการเติมขอบ (Padding) และ K คือขนาดตัวกรอง นอกจากนี้ จำนวนพารามิเตอร์ของชั้น Convolution สามารถคำนวณได้จากสมการ



รูปที่ 2.11 แสดงการทำคอนโวลูชัน [11]

2.2.3.2 ชั้นฟังก์ชันกระตุ้น (ReLU: Rectified Linear Unit Activation Layer) ทำหน้าที่เป็นฟังก์ชันการกระทำ (Activation Function) ซึ่งเป็นความสัมพันธ์ที่ไม่เป็นเชิงเส้น (Nonlinear) และช่วยในการแก้ปัญหา Gradient Vanishing ในระหว่างฝึกฝนข้อมูล สมการของ ReLU Function คือ

$$ReLU(x) = \max(0, x)$$

ซึ่งหมายความว่าถ้าอินพุต $x > 0$ เอาต์พุตจะเท่ากับ x แต่ถ้าอินพุต $x \leq 0$ เอาต์พุตจะเท่ากับ 0

2.2.3.3 ชั้นพูลลิง (Pooling Layer) ทำหน้าที่ลดขนาดของคุณลักษณะหลักของข้อมูล (Feature Map) ที่ถูกสร้างขึ้นจากชั้น Convolution ก่อนหน้า เพื่อลดความซับซ้อนของแบบจำลอง และป้องกันไม่ให้เกิดแบบจำลองมีความจำเพาะกับข้อมูลที่ใช้ฝึกฝนมากเกินไป (Overfitting) การคำนวณขนาดเอาต์พุตจะใช้สมการ

$$H_{out} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1$$

และ

$$W_{out} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1$$

โดยการพูลลิงมีหลายประเภท เช่น Max Pooling ซึ่งเป็นการเลือกค่ามากที่สุดจากแต่ละ patch ด้วยสมการ


$$y = \max_{(u,v) \in patch} a_{u,v}$$

และ Average Pooling ซึ่งเป็นการเลือกค่าเฉลี่ยของค่าทั้งหมดใน patch ด้วยสมการ

$$y = \frac{1}{K^2} \sum_{(u,v) \in patch} a_{u,v}$$

2.2.3.4 ชั้นทำให้แบนราบ (Flatten Layer) ทำหน้าที่แปลง Input ให้เป็น Output ที่เป็นเวกเตอร์ (vector) 1 มิติ ซึ่งมักจะใช้หลังจาก Convolutional Layer หรือ Pooling Layer เพื่อปรับโครงสร้างข้อมูล (Reshaping) สำหรับส่งต่อไปยังชั้นถัดไป หลักการทำงานคือกำหนดให้ Feature Map มีขนาด $H \times W \times C$ ระบบจะเปลี่ยนข้อมูลเป็นเวกเตอร์ขนาด $N = H \times W \times C$ โดย N คือจำนวนองค์ประกอบทั้งหมดของ Feature Map ดังนั้น Output ของ Flatten Layer ที่เป็นเวกเตอร์ 1 มิติจะเขียนในรูปสมการได้เป็น

$$y = [x_1, x_2, x_3, \dots, x_N]$$



รูปที่ 2.12 แสดงการทำ Flattening ได้ Output แบบเวกเตอร์ 1 มิติ [12]

2.2.3.5 ชั้นเชื่อมต่อสมบูรณ์ (Fully Connected Layer) เป็นโครงสร้างที่นิวรอนทุกตัวในชั้นนี้จะเชื่อมต่อกับอินพุตทุกตัวจากชั้นก่อนหน้า ทำหน้าที่รวมพีเจอร์ทั้งหมดที่ถูกสกัดมาจากชั้นก่อนหน้า เพื่อนำไปใช้ในการจำแนกผลลัพธ์หรือการประมาณค่า โดยเริ่มต้นจากการคำนวณผลรวมเชิงเส้น (Linear Combination) ด้วยสมการ

$$z = Wx + b$$

โดยที่ x คือเวกเตอร์อินพุต, W คือเมทริกซ์น้ำหนัก, b คือเวกเตอร์ไบแอส, และ z คือผลรวมเชิงเส้น จากนั้นจะนำค่า z ไปผ่านฟังก์ชันกระตุ้น (Activation Function) เพื่อให้ได้ผลลัพธ์ หากเป็นการจำแนกแบบสองคลาสจะนิยมใช้ฟังก์ชัน Sigmoid ที่มีสมการคือ

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

แต่สำหรับงานจำแนกหลายคลาสจะใช้ฟังก์ชัน Softmax ซึ่งมีสมการคือ

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

โดย K คือจำนวนคลาสทั้งหมด และ z_i คือค่า logit ของคลาสที่ i

2.2.4 สถาปัตยกรรม Extreme Inception (Xception)

สถาปัตยกรรม Xception เป็นโครงข่ายประสาทเทียมแบบคอนโวลูชันเชิงลึก (Deep Convolutional Neural Network) ที่พัฒนาขึ้นโดย François Chollet ผู้พัฒนาไลบรารี Keras และนำเสนอในปี ค.ศ. 2017 โดยมีพื้นฐานมาจากการตีความใหม่ของสถาปัตยกรรม Inception (โดยเฉพาะ Inception V3) ซึ่งเดิมทีโมดูล Inception ถูกออกแบบมาเพื่อให้เครือข่ายสามารถเรียนรู้ความสัมพันธ์เชิงพื้นที่ (Spatial Correlations) และความสัมพันธ์ข้ามช่องสี (Cross-channel Correlations) ไปพร้อมกันได้อย่างมีประสิทธิภาพ ผ่านการใช้ตัวกรองหลายขนาดทำงานคู่ขนานกันภายในโมดูลเดียว

Chollet ได้ตั้งข้อสมมติฐานว่า หากนำแนวคิดของ Inception มาผลักดันไปจนถึงขีดสุด (Extreme) กล่าวคือ แยกการเรียนรู้ความสัมพันธ์เชิงพื้นที่และความสัมพันธ์ข้ามช่องสีออกจากกันโดยสมบูรณ์ (Fully Decoupled) แทนที่จะให้ทำงานร่วมกันบางส่วนแบบโมดูล Inception ดั้งเดิม จะทำให้เครือข่ายมีประสิทธิภาพในการใช้พารามิเตอร์ (Parameter Efficiency) สูงขึ้น โดยที่จำนวนพารามิเตอร์รวมของ Xception (ประมาณ 22.8 ล้านพารามิเตอร์) ใกล้เคียงกับ Inception V3 (ประมาณ 23.6 ล้านพารามิเตอร์) แต่ให้ผลความแม่นยำที่สูงกว่าเมื่อทดสอบบนชุดข้อมูล ImageNet ด้วยเหตุนี้ Xception จึงถูกมองว่าเป็นจุดกึ่งกลางทางแนวคิดระหว่างสถาปัตยกรรม Inception กับเทคนิค Depthwise Separable Convolution ซึ่งเดิมถูกใช้ในงานด้าน mobile/embedded vision เช่น MobileNet

2.2.4.1 กลไกของคอนโวลูชันแบบแยกส่วนตามความลึก (Depthwise Separable Convolution) Xception จะไม่ใช้คอนโวลูชันแบบมาตรฐานที่ประมวลผลทั้งพื้นที่และช่องสีพร้อมกัน แต่จะแยกกระบวนการออกเป็น 2 ขั้นตอนทางคณิตศาสตร์ที่ทำงานต่อเนื่องกัน ดังนี้

ขั้นตอนที่ 1: Depthwise Convolution

ทำหน้าที่ประมวลผลลักษณะเชิงพื้นที่โดยใช้ตัวกรองแบบ 2 มิติ ทาบลงบนแต่ละช่องสีของข้อมูลอินพุตแบบแยกอิสระจากกัน (ไม่มีการรวมข้อมูลข้ามช่องสี) สมมติให้ข้อมูลอินพุต X มีขนาด $H \times W \times M$ และตัวกรอง K มีขนาด $D_K \times D_K$ สมการการคำนวณสำหรับแต่ละช่องสี m คือ

$$Y_{i,j,m} = \sum_{u=1}^{D_K} \sum_{v=1}^{D_K} K_{u,v,m} \cdot X_{i+u-1,j+v-1,m}$$

ผลลัพธ์ Y ที่ได้จะมีจำนวนช่องสีเท่ากับอินพุตเดิม (M ช่องสี)

ขั้นตอนที่ 2: Pointwise Convolution


ทำหน้าที่รวมความสัมพันธ์ข้ามช่องสี โดยใช้ตัวกรองขนาด 1×1 ทาบลงบนผลลัพธ์ Y ที่ได้จากขั้นตอนแรก เพื่อสร้างโครงสร้างเชิงเส้นที่ผสมผสานข้อมูลจากทุกช่องสีเข้าด้วยกันให้ได้จำนวนช่องสีเอาต์พุต N ตามที่ต้องการ สมการคือ

$$Z_{i,j,n} = \sum_{m=1}^M W_{m,n} \cdot Y_{i,j,m}$$

โดยที่ W คือเมทริกซ์น้ำหนักของคอนโวลูชันขนาด 1×1

ข้อได้เปรียบด้านการคำนวณ: เมื่อเปรียบเทียบจำนวนพารามิเตอร์ระหว่างคอนโวลูชันมาตรฐานกับ Depthwise Separable Convolution พบว่าคอนโวลูชันมาตรฐานที่มีตัวกรองขนาด $DK \times DK$ จำนวน N ตัว บนอินพุต M ช่องสี จะมีจำนวนพารามิเตอร์เท่ากับ $DK \times DK \times M \times N$ ในขณะที่ Depthwise Separable Convolution จะใช้พารามิเตอร์เพียง $(DK \times DK \times M) + (M \times N)$ ซึ่งลดจำนวนพารามิเตอร์และปริมาณการคำนวณ (FLOPs) ลงได้อย่างมีนัยสำคัญ โดยเฉพาะเมื่อ N มีค่าสูง ส่งผลให้โมเดลมีขนาดเล็กลงและฝึกฝนได้เร็วขึ้นโดยไม่สูญเสียความสามารถในการสกัดคุณลักษณะมากนัก

หมายเหตุสำคัญทางสถาปัตยกรรม: จุดแตกต่างหลักของ Xception เมื่อเทียบกับโครงข่ายอื่นที่ใช้ Depthwise Separable Convolution (เช่น MobileNet) คือ จะไม่มีการใช้ฟังก์ชันกระตุ้น (Non-linearity Activation) เช่น ReLU คั่นกลางระหว่างขั้นตอน Depthwise และ Pointwise เนื่องจากงานวิจัยพบว่าการใส่ฟังก์ชันกระตุ้นระหว่างกลางบนพื้นที่ลักษณะที่มีความลึกต่ำ (Shallow Feature Spaces) จะทำให้สูญเสียข้อมูลสำคัญและลดประสิทธิภาพของแบบจำลอง



รูปที่ 2.13 กลไกของคอนโวลูชันแบบแยกส่วนตามความลึก(Depthwise Separable Convolution)
[13]

2.2.4.2 การเชื่อมต่อแบบข้าม (Residual Connections) Xception นำกลไกการเชื่อมต่อแบบข้าม (Skip Connections) มาประยุกต์ใช้ในแทบทุกบล็อกคอนโวลูชัน เพื่อป้องกันปัญหาความชันหายไป (Vanishing Gradient) และช่วยให้ข้อมูลสามารถไหลผ่านเครือข่ายที่ลึกได้โดยตรง การเชื่อมต่อนี้มี 2 รูปแบบทางคณิตศาสตร์ ได้แก่

1) Identity Shortcut: เมื่อขนาดของแผนผังคุณลักษณะอินพุตและเอาต์พุตเท่ากัน

$$y = \mathcal{F}(x, \{W_i\}) + x$$

2) Projection Shortcut: เมื่อมีการลดขนาดเชิงพื้นที่ (เช่น การใช้ Stride = 2 หรือ Max Pooling) จะต้องมีการใช้ Pointwise Convolution ขนาด 1×1 ในเส้นทางลัด เพื่อปรับมิติข้อมูลให้ตรงกันก่อนทำการบวก

$$y = \mathcal{F}(x, \{W_i\}) + \mathcal{W}_s(x)$$

โดยที่ $\mathcal{W}_s$ คือการดำเนินการคอนโวลูชันขนาด 1×1 บนข้อมูลอินพุต x

การเชื่อมต่อแบบข้ามนี้ยังมีประโยชน์ในเชิงการเรียนรู้ กล่าวคือ แทนที่แต่ละบล็อกจะต้องเรียนรู้การแปลงข้อมูล (Mapping) ทั้งหมดตั้งแต่ต้น เครือข่ายเพียงต้องเรียนรู้ "ส่วนต่าง" (Residual) ที่จำเป็นต้องเพิ่มเติมจากอินพุตเดิมนั้น ซึ่งเป็นงานที่ง่ายกว่าและช่วยให้การฝึกฝนเครือข่ายที่มีความลึกระดับ 36 ชั้นเป็นไปได้อย่างมีประสิทธิภาพ


2.2.4.3 โครงสร้างการไหลของข้อมูล (Data Flow Architecture) โครงสร้างของ Xception ประกอบด้วยเลเยอร์คอนโวลูชันทั้งหมด 36 ชั้น (ไม่รวมชั้น Fully Connected ท้ายสุด) ซึ่งถูกจัดกลุ่มเป็นบล็อกแบบทิศทางเดียว (Linear Stack) โดยแบ่งการไหลของข้อมูลออกเป็น 3 ส่วนอย่างเป็นระบบ:

1) ส่วนนำเข้า (Entry Flow): ทำหน้าที่สกัดคุณลักษณะระดับต่ำ (Low-level Features) โดยรับข้อมูลภาพเข้าสู่ชั้นคอนโวลูชันมาตรฐาน 2 ชั้น ตามด้วยบล็อกของ Depthwise Separable Convolution จำนวน 3 บล็อก ซึ่งในแต่ละบล็อกจะมีการทำ Max Pooling ควบคู่ไปกับการทำ Residual Connection เพื่อลดขนาดเชิงพื้นที่ของภาพลงอย่างต่อเนื่อง

2) ส่วนกลาง (Middle Flow): ทำหน้าที่สกัดความสัมพันธ์ของคุณลักษณะระดับสูง ข้อมูลจะผ่านบล็อก Depthwise Separable Convolution ที่มีโครงสร้างเหมือนกันซ้ำกัน

จำนวน 8 บล็อก โดยในส่วนนี้จะไม่มีการทำ Max Pooling (ขนาดเชิงพื้นที่คงที่) แต่จะมีการใช้ Residual Connections ในทุกๆ บล็อก

3) ส่วนส่งออก (Exit Flow): ข้อมูลจะผ่านบล็อก Depthwise Separable Convolution พร้อมการทำ Max Pooling อีก 1 บล็อก เพื่อลดขนาดข้อมูลเป็นครั้งสุดท้าย จากนั้นจะผ่านชั้น Depthwise Separable Convolution อีก 2 ชั้นเพื่อปรับแต่งคุณลักษณะก่อนส่งเข้าสู่กระบวนการพูลลิงขั้นสุดท้าย



รูปที่ 2.14 แสดงโครงสร้างของ Xception [14]

2.2.4.4 ชั้นการพูลลิงแบบเฉลี่ยทั่วโลก (Global Average Pooling: GAP) ในส่วนท้ายสุดของสถาปัตยกรรม Xception จะไม่ใช่ชั้นทำให้แบนราบ (Flatten Layer) และชั้นเชื่อมต่อสมบูรณ์ (Fully Connected Layer) ขนาดใหญ่ที่ใช้พารามิเตอร์จำนวนมหาศาล แต่จะใช้ชั้น Global Average Pooling เข้ามาแทนที่ โดยทำการหาค่าเฉลี่ยของแผนผังคุณลักษณะแต่ละช่องสี่เหลี่ยมให้เหลือเพียงค่าเดียว สมการคือ

$$y_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_{i,j,c}$$

ผลลัพธ์ที่ได้จะเป็นเวกเตอร์ 1 มิติ ที่พร้อมส่งเข้าสู่ชั้น Softmax ในขั้นตอนสุดท้าย เพื่อคำนวณการกระจายความน่าจะเป็นสำหรับการจำแนกคลาส การใช้ GAP ช่วยลดปัญหา Overfitting และลดภาระการคำนวณได้อย่างมีนัยสำคัญ

2.2.5 สถาปัตยกรรม Multi-task Cascaded Convolutional Networks (MTCNN)

MTCNN เป็นสถาปัตยกรรมโครงข่ายประสาทเทียมแบบเรียงซ้อน (Cascaded) ที่ถูกออกแบบมาเพื่องานตรวจจับใบหน้า (Face Detection) และการระบุตำแหน่งจุดสังเกตบนใบหน้า (Facial Landmark Alignment) ไปพร้อมๆ กันผ่านเทคนิคการเรียนรู้แบบหลายงาน (Multi-task Learning) โดยทำงานผ่านโครงข่ายย่อย 3 โครงข่ายที่ทำหน้าที่คัดกรองข้อมูลอย่างเป็นลำดับขั้น (Coarse-to-Fine) ทำให้มีความแม่นยำสูงและทำงานได้แบบเรียลไทม์ โครงสร้างและสมการที่เกี่ยวข้องมีรายละเอียดดังนี้

2.2.5.1 สถาปัตยกรรมเครือข่ายย่อยแบบเรียงซ้อน (Cascaded Architecture)


กระบวนการทำงานของ MTCNN จะไม่ประมวลผลภาพในคราวเดียว แต่จะใช้โครงข่ายย่อย 3 ลำดับขั้น (P-Net, R-Net, O-Net) ทำหน้าที่คัดกรองข้อมูลแบบหยาบไปหาละเอียด (Coarse-to-Fine) ร่วมกับการปรับขนาดภาพ (Image Pyramid) ดังนี้

กระบวนการสร้างพีระมิดภาพ (Image Pyramid): ก่อนส่งเข้าโครงข่าย ภาพถ่ายต้นฉบับจะถูกปรับย่อขนาดลงหลายระดับ (Scaling) อย่างต่อเนื่อง เพื่อสร้างเป็นพีระมิดภาพ (Image Pyramid) วิธีนี้ช่วยให้ระบบสามารถตรวจจับใบหน้าที่มีขนาดแตกต่างกันได้ ไม่ว่าจะเป็นใบหน้าที่อยู่ใกล้กล้อง (มีขนาดใหญ่) หรือใบหน้าที่อยู่ไกลออกไป (มีขนาดเล็ก) โดยใช้ตัวกรองขนาดเดียวกันในการกวาดหา

ขั้นที่ 1: P-Net (Proposal Network): เป็นโครงข่ายแบบ Fully Convolutional Network (FCN) ที่ทำหน้าที่หลักในการสแกนภาพในทุกสเกลอย่างรวดเร็ว เพื่อค้นหาพื้นที่ที่มีความเป็นไปได้สูงว่าจะเป็นใบหน้า พร้อมทั้งสร้างกรอบสี่เหลี่ยมเบื้องต้น (Candidate Bounding Boxes) และทำนายค่าปรับเทียบตำแหน่ง (Bounding Box Regression) เนื่องจาก P-Net ประมวลผลแบบกวาดหาพื้นที่กว้าง จึงทำให้เกิดกรอบสี่เหลี่ยมจำนวนมากที่ซ้อนทับกัน ระบบจึงต้องนำผลลัพธ์ที่ได้ไปเข้าสู่กระบวนการกรองซ้ำด้วยวิธี Non-Maximum Suppression (NMS) เพื่อคัดกรองกรอบที่ซ้ำซ้อนออกในเบื้องต้น


ขั้นที่ 2: R-Net (Refine Network): รับกรอบสี่เหลี่ยมที่ผ่านการคัดกรองมาจาก P-Net มาปรับขนาดให้เท่ากัน แล้วส่งต่อเข้ามายังโครงข่าย R-Net ซึ่งมีโครงสร้างเป็น Fully Connected Network ที่มีความซับซ้อนและมีพารามิเตอร์มากกว่า หน้าที่หลักของ R-Net คือการทำหน้าที่เป็นตัวกรองที่เข้มงวดขึ้น เพื่อกำจัดกรอบสี่เหลี่ยมปลอม (False Positives) ที่ไม่ใช่ใบหน้าที่ังไปอย่างแม่นยำ พร้อมทั้งปรับแต่งพิกัดของกรอบสี่เหลี่ยมให้มีความกระชับและแม่นยำยิ่งขึ้น ก่อนจะนำไปทำ NMS ซ้ำอีกรอบเพื่อลดจำนวนกรอบที่เหลือเฉพาะตำแหน่งที่มีความน่าเชื่อถือสูง

ขั้นที่ 3: O-Net (Output Network): เป็นโครงข่ายลำดับสุดท้ายที่มีความลึกและซับซ้อนที่สุด ทำหน้าที่คล้ายกับ R-Net แต่ให้ผลลัพธ์ที่ละเอียดยิ่งขึ้น โดยนอกจากจะทำหน้าที่คัดกรองกรอบสี่เหลี่ยมใบหน้าที่ดีที่สุดแล้ว O-Net ยังทำหน้าที่ทำนายพิกัดของจุดสังเกตบนใบหน้า (Facial Landmarks) จำนวน 5 จุดสำคัญ ได้แก่ ตำแหน่งดวงตาทั้งสองข้าง, จมูก, และมุมปากทั้งสองข้าง ข้อมูลจุดสังเกตเหล่านี้มีความสำคัญอย่างมากในการนำมาใช้ปรับหมุนและตัดแต่งภาพใบหน้า (Face Alignment and Cropping) ให้มีความตั้งตรงและได้สัดส่วนที่ถูกต้องสมบูรณ์



รูปที่ 2.15 โครงสร้างการทำงานเชิงลำดับขั้นจากภาพต้นฉบับผ่าน P-Net, R-Net และ O-Net

[15]



รูปที่ 2.16 แสดงกระบวนการ Image Pyramid และ NMS [16]

2.2.5.2 กระบวนการยับยั้งค่าที่ไม่ใช่ค่าสูงสุด (Non-Maximum Suppression: NMS) ในทุกๆ ขั้นตอนของการตรวจจับด้วย P-Net และ R-Net โมเดลจะสร้างกรอบสี่เหลี่ยม (Bounding Boxes) หลายร้อยหรือหลายพันกรอบที่ต่างก็ชี้ไปยังใบหน้าเดียวกัน เพื่อป้องกันไม่ให้ระบบส่งกรอบที่ทับซ้อนกันเหล่านี้ไปยังขั้นตอนถัดไป MTCNN จึงใช้กระบวนการ Non-Maximum Suppression (NMS) เข้ามาจัดการ โดยมีกลไกทางคณิตศาสตร์และการคำนวณดังนี้

1) การประเมินค่าความน่าจะเป็น (Confidence Score): กรอบสี่เหลี่ยมทุกกรอบที่ถูกสร้างขึ้นจะมาพร้อมกับค่าความน่าจะเป็นที่บอกว่าพื้นที่นั้นคือใบหน้า กรอบที่มีคะแนนต่ำกว่าเกณฑ์ที่กำหนดจะถูกตัดทิ้งทันที

2) การคำนวณพื้นที่ทับซ้อนด้วยค่า IoU (Intersection over Union): สำหรับกรอบที่เหลือ ระบบจะนำมาจับคู่เปรียบเทียบความทับซ้อนระหว่างกรอบที่ 1 (Box_1) และกรอบที่ 2 (Box_2) ผ่านสมการการคำนวณอัตราส่วนพื้นที่ทับซ้อน:

$$IoU = \frac{Area(Box_1 \cap Box_2)}{Area(Box_1 \cup Box_2)}$$

โดยตัวเศษคือพื้นที่ส่วนที่ซ้อนทับกันระหว่างสองกรอบ และตัวส่วนคือพื้นที่รวมทั้งหมดของทั้งสองกรอบรวมกัน

3) การคัดกรองตัดสินใจ: หากค่า IoU ที่คำนวณได้มีค่าสูงกว่าเกณฑ์กำหนด (Threshold) หมายความว่ากรอบทั้งสองกำลังครอบคลุมใบหน้าตำแหน่งเดียวกัน ระบบจะทำการเปรียบเทียบค่า Confidence Score ระหว่างสองกรอบนั้น และจะทำการ "ตัดทิ้ง (Suppression)" กรอบที่มีคะแนนต่ำกว่าออกไป คงเหลือไว้เฉพาะกรอบที่มีค่าความสูงที่สุดเพียงกรอบเดียว กระบวนการนี้ทำซ้ำจนกระทั่งได้กรอบสี่เหลี่ยมที่สะอาดและแม่นยำที่สุดสำหรับนำไปใช้ตัดภาพใบหน้าต่อไป

2.2.6 Confusion Matrix

Confusion Matrix คือ เครื่องมือสำคัญในการประเมินผลลัพธ์ของการทำนาย (Prediction) ที่ทำนายจากโมเดลที่เราสร้างขึ้นใน Machine Learning โดยมีไอดีเดียวจากการวัดว่า สิ่งที่เราคิด (โมเดลทำนาย) กับสิ่งที่เกิดขึ้นจริง มีสัดส่วนเป็นอย่างไร

Confusion Matrix

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

รูปที่ 2.17 Confusion Matrix [17]

เราสามารถใช้ Confusion Matrix มาคำนวณการประเมินประสิทธิภาพของการทำนายด้วยโมเดลในรูปแบบค่าต่างๆ ได้หลายค่า ได้แก่:

2.2.6.1 ค่าความถูกต้อง (Accuracy)

ค่าที่ใช้วัดความถูกต้องโดยรวมของโมเดลจำแนกประเภท (Classification Model) โดยพิจารณาว่าโมเดลสามารถทำนายผลได้ถูกต้องกี่ครั้งจากจำนวนตัวอย่างทั้งหมด ทั้งในกรณีที่ทำนายว่าข้อมูลเป็นคลาสบวก (Positive) หรือคลาสลบ (Negative)

สมการคำนวณ:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

โดยที่:

TP (True Positive) คือ จำนวนตัวอย่างที่โมเดลทำนายว่าเป็นบวก และเป็นบวกจริง

TN (True Negative) คือ จำนวนตัวอย่างที่โมเดลทำนายว่าเป็นลบ และเป็นลบจริง

FP (False Positive) คือ จำนวนตัวอย่างที่โมเดลทำนายว่าเป็นบวก แต่ความจริงเป็นลบ

FN (False Negative) คือ จำนวนตัวอย่างที่โมเดลทำนายว่าเป็นลบ แต่ความจริงเป็นบวก

2.2.6.2 ค่าความแม่นยำเชิงบวก (Precision)

ค่าที่ใช้วัด “ความแม่นยำเชิงบวก” (Positive Predictive Value) ของโมเดลจำแนกประเภท โดยบอกว่าในบรรดาตัวอย่างทั้งหมดที่โมเดลทำนายว่าเป็นคลาสบวก (Positive) นั้น มีสัดส่วนเท่าใดที่เป็นบวกจริง

สมการคำนวณ:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Precision จึงเป็นตัวชี้วัดความน่าเชื่อถือของผลการทำนายบวก ถ้า Precision มีค่าสูง หมายความว่าผลบวกที่โมเดลทำนายมานั้นมีความถูกต้องสูง ในทางกลับกัน ถ้า Precision ต่ำ หมายความว่ามีการทำนายผลบวกที่ผิดพลาด (False Positive) สูง

2.2.6.3 ค่าความครอบคลุม (Recall)

ค่าที่ใช้วัด “ความครอบคลุม” (Sensitivity หรือ True Positive Rate) ของโมเดลจำแนกประเภท โดยบอกว่าในบรรดาตัวอย่างทั้งหมดที่เป็นคลาสบวก (Positive) จริง โมเดลสามารถทำนายถูกต้องเป็นบวกได้กี่เปอร์เซ็นต์

สมการคำนวณ:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Recall จึงเป็นตัวชี้วัดความสามารถของโมเดลในการตรวจจับตัวอย่างที่เป็นบวกทั้งหมด ถ้า Recall มีค่าสูง หมายความว่าโมเดลสามารถจับตัวอย่างบวกได้ครบถ้วนหรือเกือบครบถ้วน ในทางกลับกัน ถ้า Recall ต่ำ หมายความว่ามีการทำนายบวกจริงที่ถูกละทิ้งไป (False Negative) เป็นจำนวนมาก

2.2.6.4 F1-score

ค่าที่ใช้วัดประสิทธิภาพของโมเดลจำแนกประเภทโดยผสมผสาน Precision และ Recall เข้าด้วยกันในลักษณะค่าเฉลี่ยเชิงฮาร์โมนิก (Harmonic Mean) เพื่อสะท้อนทั้งความแม่นยำเชิงบวกและความครอบคลุมของการตรวจจับในค่าเดียว

สมการคำนวณ:


$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

ค่า F1-score จะมีค่าระหว่าง 0 ถึง 1 (หรือ 0% ถึง 100%) โดยค่าที่สูงบ่งบอกว่าโมเดลมีทั้ง Precision และ Recall สูง และมีความสมดุลระหว่างการลดการทำนายบวกผิด (False Positive) และการลดการพลาดตัวอย่างบวกจริง (False Negative) จุดเด่นของ F1-score คือช่วยให้การประเมินโมเดลมีความสมดุล ไม่เอนเอียงไปเพียงด้านใดด้านหนึ่ง

2.3 เทคโนโลยีที่ใช้ในการพัฒนาระบบ

2.3.1 Visual Studio Code

Visual Studio Code คือ โปรแกรม Code Editor ที่พัฒนาโดย Microsoft ซึ่งถูกนำมาใช้เป็นเครื่องมือหลักสำหรับเขียน แก้ไข และตรวจสอบความผิดปกติของชุดคำสั่งในโครงการนี้ ตัวโปรแกรมมีจุดเด่นด้านประสิทธิภาพสูง ทำงานได้อย่างรวดเร็ว มีส่วนขยาย (Extensions) ที่หลากหลายเพื่อรองรับภาษาและเฟรมเวิร์กที่ใช้ในการพัฒนาเว็บแอปพลิเคชันและการประมวลผลปัญญาประดิษฐ์ ทำให้การบริหารจัดการโค้ดและการพัฒนาโปรแกรมมีความสะดวกรวดเร็วยิ่งขึ้น



รูปที่ 2.18 Visual Studio Code

2.3.2 Python

Python คือ ภาษาโปรแกรมคอมพิวเตอร์ระดับสูงที่ถูกออกแบบมาให้เป็นภาษาที่มีโครงสร้างและไวยากรณ์อ่านง่าย ไม่ซับซ้อน มีการทำงานแบบ Interpreter ซึ่งแปลชุดคำสั่งทีละบรรทัด ในโครงการนี้ ภาษา Python ได้ถูกนำมาใช้เป็นภาษาหลักในการพัฒนาโมเดลปัญญาประดิษฐ์และการประมวลผลการเรียนรู้เชิงลึก เนื่องจากรองรับไลบรารีและเฟรมเวิร์กด้านปัญญาประดิษฐ์ที่สำคัญจำนวนมาก เช่น PyTorch สำหรับการสร้างและฝึกฝนโมเดล Xception และการจัดการประมวลผลข้อมูลภาพ ตลอดจนการพัฒนาโครงสร้างการทำงานในส่วนหลัง (Backend) เพื่อให้สามารถเชื่อมต่อและทำงานร่วมกับส่วนติดต่อผู้ใช้งานบนเว็บแอปพลิเคชันได้อย่างมีประสิทธิภาพ

```


1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 def generate_mandelbrot(xmin, xmax, ymin, ymax, width, height, max_iter):
5     r1 = np.linspace(xmin, xmax, width)
6     r2 = np.linspace(ymin, ymax, height)
7     c = r1 + r2[:, None] * 1j
8     z = np.zeros(c.shape, dtype=complex)
9     output = np.zeros(c.shape, dtype=int)
10
11     for i in range(max_iter):
12         mask = np.abs(z) <= 2
13         z[mask] = z[mask]**2 + c[mask]
14         output[mask] += 1
15
16     return output
17
18 plt.figure(figsize=(8, 8))
19 image = generate_mandelbrot(-2.0, 0.5, -1.25, 1.25, width=1000, height=1000, max_iter=256)
20
21 plt.imshow(image.T, extent=[-2.0, 0.5, -1.25, 1.25], cmap="inferno")
22 plt.colorbar(label="Iterations")
23 plt.title("Mandelbrot Fractal - Python Illustration")
24 plt.xlabel("Re")
25 plt.ylabel("Im")
26 plt.savefig("mandelbrot_figure.png", dpi=300, bbox_inches="tight")
27 plt.show()

```

รูปที่ 2.19 Python

2.3.3 Kaggle Notebook

Kaggle Notebook คือ แพลตฟอร์มการประมวลผลคลาวด์ (Cloud-based Computing Platform) ที่ให้บริการสภาพแวดล้อมการพัฒนาโค้ดภาษา Python ผ่านเว็บเบราว์เซอร์ โดยมีทรัพยากรฮาร์ดแวร์ประมวลผลประสิทธิภาพสูง เช่น หน่วยประมวลผลกราฟิก (GPU) และหน่วยประมวลผล Tensor (TPU) สนับสนุนให้ใช้งานได้ฟรี ในโครงการนี้ Kaggle Notebook ได้ถูกนำมาใช้เป็นเครื่องมือหลักสำหรับกระบวนการฝึกฝน (Training) และทดสอบโมเดลปัญญาประดิษฐ์ เนื่องจากโครงการมีความจำเป็นต้องประมวลผลชุดข้อมูลวิดีโอขนาดใหญ่ ซึ่งต้องใช้กำลังการประมวลผลสูง การใช้งาน Kaggle Notebook จึงช่วยอำนวยความสะดวกในการรันโค้ด PyTorch ลดภาระทางด้านฮาร์ดแวร์ของเครื่องคอมพิวเตอร์ส่วนบุคคล และช่วยให้กระบวนการสร้างโมเดล Xception สำเร็จลุล่วงได้อย่างมีประสิทธิภาพ



รูปที่ 2.20 Kaggle Notebook

2.3.4 HTML

HTML (HyperText Markup Language) คือ ภาษามาตรฐานที่ใช้ในการสร้างโครงสร้าง และกำหนดเนื้อหาของเว็บไซต์ โดยทำหน้าที่จัดวางองค์ประกอบต่างๆ เช่น ข้อความ รูปภาพ และฟอร์มการอัปโหลดข้อมูล ในโครงงานนี้ HTML ได้ถูกนำมาใช้เป็นส่วนประกอบหลักในการพัฒนา ส่วนติดต่อผู้ใช้งาน (User Interface) ของเว็บแอปพลิเคชัน เพื่อให้ผู้ใช้ทั่วไปสามารถเข้าถึงระบบ อัปโหลดไฟล์วิดีโอ และแสดงผลการตรวจสอบวิดีโอที่อัปโหลดได้อย่างเป็นระเบียบและใช้งานง่าย

```
1 <!DOCTYPE html>
2 <html lang="th">
3 <head>
4   <meta charset="UTF-8">
5   <title>Deepfake Detection Illustration</title>
6   <style>
7     body {
8       font-family: sans-serif;
9       background-color: #f4f6f9;
10      display: flex;
11      justify-content: center;
12      align-items: center;
13      height: 100vh;
14      margin: 0;
15    }
16    .card {
17      background: white;
18      padding: 20px;
19      border-radius: 8px;
20      box-shadow: 0 4px 6px rgba(0,0,0,0.1);
21      text-align: center;
22    }
23  </style>
24 </head>
25 <body>
26   <div class="card">
27     <h2>AI System UI Preview</h2>
28     <p>ระบบตรวจสอบวิดีโออัปโหลดในหน้าด้วยปัญญาประดิษฐ์</p>
29   </div>
30 </body>
31 </html>
```

รูปที่ 2.21 HTML

2.3.5 CSS

CSS (Cascading Style Sheets) คือ ภาษาที่ใช้สำหรับกำหนดรูปแบบและการแสดงผลของเอกสาร HTML เพื่อให้เว็บไซต์มีความสวยงาม เป็นระเบียบ และอ่านง่าย โดยแยกส่วนของการจัดหน้าและการตกแต่งออกจากเนื้อหาหลัก ในโครงงานนี้ CSS ได้ถูกนำมาใช้ในการตกแต่งส่วนติดต่อผู้ใช้งาน (User Interface) ของเว็บแอปพลิเคชัน เช่น การกำหนดสี ตัวอักษร การจัดวางเลย์เอาต์ และการออกแบบหน้าจอให้รองรับการใช้งานบนอุปกรณ์ต่างๆ ได้อย่างมีประสิทธิภาพ

```

1  body {
2      font-family: 'Sarabun', sans-serif;
3      background-color: #f4f6f9;
4      color: #2c3e50;
5      margin: 0;
6      padding: 20px;
7  }
8
9  .container {
10     background: #ffffff;
11     padding: 25px;
12     border-radius: 8px;
13     box-shadow: 0 4px 6px rgba(0, 0, 0, 0.1);
14     max-width: 600px;
15     margin: auto;
16 }
17
18 h2 {
19     color: #1a252f;
20     border-bottom: 2px solid #e0e0e0;
21     padding-bottom: 10px;
22 }

```

รูปที่ 2.22 CSS

2.3.6 JavaScript

JavaScript คือ ภาษาโปรแกรมคอมพิวเตอร์ที่ใช้ในการสร้างความเคลื่อนไหวและเพิ่มความสามารถในการโต้ตอบ (Interactivity) ให้กับเว็บไซต์ ทำงานฝั่งผู้ใช้งาน (Client-side) เพื่อให้เว็บแอปพลิเคชันสามารถตอบสนองต่อการกระทำของผู้ใช้ได้แบบเรียลไทม์ ในโครงการนี้ JavaScript ได้ถูกนำมาใช้เพื่อจัดการการทำงานส่วนหน้าเว็บ เช่น การตรวจสอบความถูกต้องของไฟล์วิดีโอก่อนทำการอัปโหลด การสร้างเอฟเฟกต์หรือหน้าต่างแจ้งเตือนสถานะการประมวลผล และการเชื่อมต่อการทำงานกับระบบหลังบ้านเพื่อแสดงผลผลการตรวจสอบวิดีโอที่อัปโหลดให้ผู้ใช้งานทราบได้อย่างรวดเร็วและราบรื่น

```

1  function checkDeepfakeStatus(videoId) {
2      console.log(`กำลังตรวจสอบวิดีโอ ID: ${videoId}...`);
3
4      const isFake = Math.random() < 0.5;
5      const result = {
6          id: videoId,
7          status: "Completed",
8          prediction: isFake ? "Deepfake Detected (วิดีโอปลอมแปลง)" : "Real Video (วิดีโอจริง)",
9          confidence: (Math.random() * (99 - 85) + 85).toFixed(2) + "%"
10     };
11
12     return result;
13 }
14
15 const analysisResult = checkDeepfakeStatus("VID_2026_001");
16 console.log("ผลการวิเคราะห์:", analysisResult);

```

รูปที่ 2.23 JavaScript

2.4 งานวิจัยที่เกี่ยวข้อง

2.4.1 Comparison of ResNet, EfficientNet, and Xception architectures for deepfake detection

Lipianina-Honcharenko, Telka และ Melnyk ได้เปรียบเทียบประสิทธิภาพของสถาปัตยกรรม ResNet, EfficientNet และ Xception โดยตรงบนงานตรวจจับวิดีโอปลอม โดยใช้ชุดข้อมูลจาก Kaggle Deepfake Detection Challenge ซึ่งมีลักษณะไม่สมดุลระหว่างคลาส (วิดีโอจริงร้อยละ 12.5 และวิดีโอปลอมร้อยละ 87.5) ผลการทดลองพบว่า Xception ให้ความแม่นยำสูงที่สุดที่ร้อยละ 87.7 พร้อมค่าความแม่นยำและความครอบคลุมที่สมดุลระหว่างสองคลาส ในขณะที่ ResNet แม้จะมีเสถียรภาพในการฝึกฝนแต่ไม่สามารถจำแนกวิดีโอจริงได้เลยแม้แต่ตัวอย่างเดียว งานวิจัยนี้ยังชี้ข้อจำกัดร่วมของทั้งสามโมเดล คือมีแนวโน้ม overfitting ในช่วงท้ายของการฝึกฝนเมื่อข้อมูลไม่สมดุล โครงการนี้นำผลเปรียบเทียบดังกล่าวมาสนับสนุนการเลือก Xception เนื่องจากให้ผลลัพธ์ที่สมดุลระหว่างคลาสมากกว่าสถาปัตยกรรมอื่นภายใต้เงื่อนไขข้อมูลไม่สมดุล ซึ่งใกล้เคียงกับลักษณะชุดข้อมูลจริงที่ใช้ในโครงการ [30]

2.4.2 Deepfake detection: humans vs. machines

Korshunov และ Marcel ได้เปรียบเทียบโมเดล Xception และ EfficientNet-B4 ที่ฝึกฝนด้วยชุดข้อมูล FaceForensics++ (Google subset) และ Celeb-DF โดยประเมินทั้งบนชุดทดสอบเดิมและบนวิดีโอที่ไม่เคยพบมาก่อนจากฐานข้อมูลของ Facebook งานวิจัยนี้แสดงให้เห็นข้อจำกัดสำคัญด้านการทั่วไปของโมเดล (Generalization) กล่าวคือ แม้ทั้งสองโมเดลจะให้ค่า AUC เกือบร้อยละ 100 เมื่อทดสอบบนชุดข้อมูลเดียวกับที่ฝึกฝน แต่ค่า AUC กลับลดลงเหลือเพียงประมาณร้อยละ 70–74 เมื่อทดสอบกับวิดีโอที่ไม่เคยเห็นมาก่อน และยังพบว่าการรับรู้ของโมเดลไม่สัมพันธ์กับความรูสึกของมนุษย์ต่อความสมจริงของวิดีโอ โครงการนี้นำข้อค้นพบด้านข้อจำกัดการทั่วไปของโมเดลมาเป็นแนวทางในการออกแบบการแบ่งชุดข้อมูล (Training/Validation/Test) และการประเมินผลอย่างระมัดระวัง [31]

2.4.3 Deepfake detection with deep learning: Convolutional neural networks versus transformers

Thing ได้ศึกษาเปรียบเทียบสถาปัตยกรรม CNN (ResNet152, XceptionNet, EfficientNet B7, HRNet) กับสถาปัตยกรรม Transformer (ViT, BEiT, Swin, CaiT) บนชุดข้อมูลตีพิมพ์ทั้งรุ่นที่สองและสาม ได้แก่ FF++ 2020, Google DFD, Celeb-DF, Deeper Forensics และ DFDC ผลการทดลองพบว่าเมื่อฝึกฝนและทดสอบบนชุดข้อมูลเดียวกัน XceptionNet, EfficientNet B7 และ HRNet ให้ผลลัพธ์ที่ดีกว่าหรือใกล้เคียงกับกลุ่ม Transformer ส่วนใหญ่ (ความแม่นยำมากกว่าร้อยละ 85 และ AUC มากกว่าร้อยละ 98) แต่เมื่อทดสอบข้ามชุดข้อมูล (Cross-dataset) ประสิทธิภาพของทุกสถาปัตยกรรมลดลงอย่างมีนัยสำคัญ เช่น โมเดล Xception ที่ฝึกด้วย FF++ 2020 เมื่อทดสอบกับ DFDC มีความแม่นยำเพียงประมาณร้อยละ 54 งานวิจัยนี้ชี้ให้เห็นทั้งจุดแข็งของ Xception ในสภาวะทดสอบแบบเดียวกับที่ฝึกฝน และข้อจำกัดร่วมของทุกสถาปัตยกรรมด้านการทั่วไปข้ามชุดข้อมูล ซึ่งโครงการนี้นำมาพิจารณาประกอบการกำหนดขอบเขตว่าระบบอาจมีความแม่นยำลดลงหากพบเทคนิคตีพิมพ์ที่ไม่อยู่ในชุดข้อมูลฝึกฝน [32]

2.4.4 DeepfakeBench: A comprehensive benchmark of deepfake detection

Yan และคณะได้พัฒนา DeepfakeBench ซึ่งเป็นกรอบการประเมินมาตรฐานสำหรับเปรียบเทียบตัวตรวจจับตีพิมพ์อย่างเป็นธรรมภายใต้เงื่อนไขการทดลองเดียวกัน โดยเปรียบเทียบสถาปัตยกรรมพื้นฐาน (Backbone) สามแบบที่มีจำนวนพารามิเตอร์ใกล้เคียงกัน ได้แก่ Xception, EfficientNet-B4 และ ResNet34 ทั้งในสถานการณ์ทดสอบภายในโดเมนเดียวกัน (Within-domain) และข้ามโดเมน (Cross-domain) ผลการศึกษาพบว่า Xception และ EfficientNet-B4 ให้ประสิทธิภาพเหนือกว่า ResNet34 อย่างสม่ำเสมอ แม้จะมีจำนวนพารามิเตอร์ใกล้เคียงกัน และยังพบว่าการใช้น้ำหนักที่ผ่านการฝึกล่วงหน้า (Pre-trained weights) ช่วยเพิ่มประสิทธิภาพของ Xception ได้ถึงประมาณร้อยละ 10 บนชุดข้อมูล DFDCP งานวิจัยนี้จึงยืนยันว่าการเลือกสถาปัตยกรรมพื้นฐานมีผลอย่างมากต่อประสิทธิภาพของตัวตรวจจับ และสนับสนุนการเลือกใช้ Xception เป็นสถาปัตยกรรมหลักของโครงการนี้ เนื่องจากมีความสม่ำเสมอของประสิทธิภาพที่ได้รับการยืนยันภายใต้กรอบการประเมินมาตรฐานที่ครอบคลุมหลายชุดข้อมูล [33]

บทที่ 3

วิธีการดำเนินการศึกษา

3.1 วิธีการดำเนินการศึกษาและรวบรวมข้อมูล

3.1.1 ขั้นตอนการดำเนินงาน

3.1.1.1 ศึกษาปัญหาและความต้องการของผู้ใช้งาน

ปัญหาการตรวจจับวิดีโอปลอมที่เฟกใบหน้า โดยเฉพาะจาก "วิดีโอที่ผ่านการปลอมแปลงด้วยเทคนิคเชิงลึกขั้นสูง" เป็นงานที่มีความซับซ้อน เนื่องจากลักษณะของวิดีโอปลอมมีความสมจริงใกล้เคียงกับวิดีโอจริงมากขึ้นเรื่อย ๆ จำเป็นต้องอาศัยความเชี่ยวชาญเฉพาะทางในการวิเคราะห์ ซึ่งมนุษย์มีข้อจำกัดด้านความสามารถในการสังเกตและไม่สามารถตรวจสอบได้อย่างครอบคลุมในทุกกรณี

3.1.1.2 รวบรวมข้อมูลและองค์ความรู้

- 1) ศึกษาข้อมูลเกี่ยวกับ Deepfake
- 2) ศึกษาข้อมูลเกี่ยวกับ การเรียนรู้ของเครื่อง และการเรียนรู้เชิงลึก
- 3) ศึกษาข้อมูลเรื่องของอัลกอริทึมสถาปัตยกรรม Xception
- 4) ค้นหาข้อมูลจากงานวิจัยที่มีความเกี่ยวข้องกับระบบงาน การเรียนรู้เชิงลึก

3.1.1.3 วิเคราะห์ระบบและออกแบบระบบ

จัดทำ Flow Chart เพื่อแสดงการไหลของข้อมูล และออกแบบส่วนต่อประสานกับผู้ใช้ทั้งผลลัพธ์บนหน้าจอ

3.1.1.4 พัฒนาและทดสอบระบบ

- 1) พัฒนาโมเดลด้วย Xception
- 2) พัฒนาเว็บไซต์

3.1.1.5 สรุปและจัดทำเอกสารโครงการ

จัดทำเอกสารโครงการฉบับสมบูรณ์และคู่มือการใช้งาน

3.1.2 รายละเอียดของระบบงาน

ระบบตรวจจับวิดีโอดีปเฟกใบหน้าด้วยปัญญาประดิษฐ์ ที่พัฒนามีฟังก์ชันการทำงานดังนี้

3.1.2.1 ฟังก์ชันหลัก

- 1) สามารถเพิ่ม และลบโมเดลที่ใช้ในการจำแนกได้
- 2) สามารถเปิด-ปิดการใช้งานโมเดลได้
- 3) สามารถจำแนกวิดีโอที่มีใบหน้าบุคคล

3.1.2.2 ฟังก์ชันหลัก

- 1) แสดงผลการวิเคราะห์เปรียบเทียบแยกตามรายโมเดล
- 2) แสดงกราฟสัดส่วนผลลัพธ์การจำแนกและค่าความเชื่อมั่นเฉลี่ย

3.1.3 เครื่องมือที่ใช้ในการศึกษา

3.1.3.1 เครื่องมือที่ใช้เก็บรวบรวมข้อมูล

การดำเนินการศึกษาค้นคว้าข้อมูลที่เกี่ยวข้องกับการทำระบบตรวจจับวิดีโอดีปเฟกใบหน้าด้วยปัญญาประดิษฐ์ ได้ศึกษาค้นคว้าเก็บรวบรวมข้อมูลต่างๆ จากการค้นคว้าทางอินเทอร์เน็ต เพื่อนำมาวิเคราะห์ออกแบบระบบ และดำเนินการศึกษาจากงานวิจัยที่เกี่ยวข้องเพื่อนำมาพัฒนาระบบงาน

3.1.3.2 เครื่องมือที่ใช้สำหรับพัฒนางาน

1) ด้านซอฟต์แวร์


- 1.1) โปรแกรม Visual Studio Code สำหรับพัฒนาโปรแกรม
- 1.2) ภาษาที่ใช้ในการพัฒนา / เฟรมเวิร์ก ได้แก่ Python, HTML, CSS, JavaScript
- 1.3) Kaggle Notebook สำหรับใช้ในการฝึกโมเดล

2) ด้านฮาร์ดแวร์

- 2.1) เครื่องคอมพิวเตอร์ที่มีหน่วยประมวลผล AMD Ryzen 7 (3.80 GHz)
- 2.2) หน่วยความจำหลัก (RAM) 16 GB


3.2 การวิเคราะห์และออกแบบระบบ

3.2.1 ภาพรวมของระบบ (System Overview)




รูปที่ 3.1 ภาพรวมของระบบ (System Overview)

3.2.2 แผนผังลำดับชั้นกระบวนการ (Hierarchical Chart)



รูปที่ 3.2 Hierarchical Chart


3.2.3 ผังงานระบบ (System Flow Chart)



รูปที่ 3.3 System Flow Chart


3.2.4 พังงาน (Flow Chart) /Algorithms/ Pseudocode

3.2.4.1 ตรวจสอบสิทธิ์




รูปที่ 3.4 ตรวจสอบสิทธิ์

3.2.4.2 จัดการโมเดลที่ใช้ในการจำแนก




รูปที่ 3.5 จัดการโมเดลที่ใช้ในการจำแนก

3.2.4.3 เพิ่มโมเดลที่ใช้ในการจำแนก




รูปที่ 3.6 เพิ่มโมเดลที่ใช้ในการจำแนก

3.2.4.4 ลบโมเดลที่ใช้ในการจำแนก




รูปที่ 3.7 ลบโมเดลที่ใช้ในการจำแนก

3.2.4.5 กำหนดสถานะการใช้งานโมเดล




รูปที่ 3.8 กำหนดสถานะการใช้งานโมเดล

3.2.4.6 วิเคราะห์วิดีโอטיפเฟกใบหน้า




รูปที่ 3.9 วิเคราะห์วิถีไอดีปเฟกไบหน้า

3.2.4.7 จำแนกวิดีโอติปเฟกใบหน้า




รูปที่ 3.10 จำแนกวิดีโอติปเฟกใบหน้า

3.2.4.8 แสดงผลการจำแนกวิดีโอטיפเฟกใบหน้า




รูปที่ 3.11 แสดงผลการจำแนกวิดีโอטיפเฟกใบหน้า

3.2.4.9 สร้างโมเดลจำแนกวิดีโอทีปเฟกใบหน้า




รูปที่ 3.12 สร้างโมเดลจำแนกวิดีโอทีปเฟกใบหน้า

3.2.4.10 แบ่งชุดข้อมูล




รูปที่ 3.13 แบ่งชุดข้อมูล

3.2.4.11 ฝึกฝนโมเดล Xception




รูปที่ 3.14 ฝึกฝนโมเดล Xception

3.2.4.12 Entry Flow




รูปที่ 3.15 Entry Flow

3.2.4. Convolution Block 1




รูปที่ 3. Convolution Block 1

3.2.4. Convolution Block 2




รูปที่ 3. Convolution Block 2

3.2.4. Entry Flow Block 1




รูปที่ 3. Entry Flow Block 1

3.2.4. Entry Flow Block 2




รูปที่ 3. Entry Flow Block 2

3.2.4. Entry Flow Block 3




รูปที่ 3. Entry Flow Block 3

3.2.4.13 Middle Flow




รูปที่ 3.16 Middle Flow

3.2.4.14 Middle Flow Block




รูปที่ 3.17 Middle Flow Block

3.2.4.14 Exit Flow




รูปที่ 3.17 Exit Flow

3.2.4.14 Exit Flow Block 1




รูปที่ 3.17 Exit Flow Block 1


3.2.4.14 Exit Flow Block 2



รูปที่ 3.17 Exit Flow Block 2


3.2.4.14 Convolution Layer






รูปที่ 3. Convolution Layer


3.2.4.14 Separable Convolution Layer



รูปที่ 3. Separable Convolution Layer


3.2.4.14 Depthwise Convolution






รูปที่ 3.17 Depthwise Convolution

3.2.4.14 Pointwise Convolution




รูปที่ 3.17 Pointwise Convolution

3.2.4.14 Padding




รูปที่ 3.17 Padding

3.2.4.14 Batch Normalization




รูปที่ 3.17 Batch Normalization

3.2.4.14 Activation Function (ReLU)




รูปที่ 3.17 Activation Function (ReLU)

3.2.4.14 Max Pooling Layer




รูปที่ 3.17 Max Pooling Layer

3.2.4.14 Residual Connection (Add)




รูปที่ 3.17 Residual Connection (Add)

3.2.4.14 Global Average Pooling Layer




รูปที่ 3.17 Global Average Pooling Layer

3.2.4.14 Fully Connected Layer




รูปที่ 3.17 Fully Connected Layer

3.2.4.14 hidden layer1




รูปที่ 3.17 hidden layer1

3.2.4.14 hidden layer2




รูปที่ 3.17 hidden layer2

3.2.4.14 Dropout




รูปที่ 3.17 Dropout

3.2.4.14 hidden layer3




รูปที่ 3.17 hidden layer3

3.2.4.14 Softmax




รูปที่ 3.17 Softmax

3.2.4.14 argmax




รูปที่ 3.17 argmax

3.2.4.24 ทดสอบโมเดล




รูปที่ 3.27 ทดสอบโมเดล

3.2.4.25 คู่มือสถิติและภาพรวมการใช้งานของระบบ




รูปที่ 3.28 สถิติและภาพรวมการใช้งานของระบบ

3.2.4.26 แสดงสถิติการอัปโหลดและผลการจำแนกภาพรวม



รูปที่ 3.29 แสดงสถิติการอัปโหลดและผลการจำแนกภาพรวม

3.2.4.27 แสดงประวัติการตรวจจับวิดีโอย้อนหลัง



รูปที่ 3.30 แสดงประวัติการตรวจจับวิดีโอย้อนหลัง

3.2.5 คำอธิบายโมดูล (Module Specification)

3.2.5.1) คำอธิบายกระบวนการ ตรวจสอบสิทธิ์

ชื่อกระบวนการ	ตรวจสอบสิทธิ์
วัตถุประสงค์	เพื่อตรวจสอบความถูกต้องของชื่อผู้ใช้และรหัสผ่านของผู้ดูแลระบบก่อนอนุญาตให้เข้าสู่ระบบบริหารจัดการ
ข้อมูลเข้า	ชื่อผู้ใช้ (username) และ รหัสผ่าน (password)
ข้อมูลออก	สิทธิ์การเข้าใช้งานระบบ (Session / Authentication Status)
แฟ้มข้อมูล	admins
ขั้นตอนการประมวลผล	1. แสดงหน้าจอเข้าสู่ระบบ 2. ป้อนชื่อผู้ใช้ และรหัสผ่าน 3. ตรวจสอบชื่อผู้ใช้และรหัสผ่านว่างหรือไม่ 3.1 ใช่ แสดงข้อความป้อนข้อมูลให้ครบ แล้วกลับไปทำข้อ 2 3.2 ไม่ใช่ ทำข้อ 4 4. ค้นหาข้อมูลผู้ดูแลระบบจากฐานข้อมูลตาราง admins 5. ตรวจสอบพบชื่อผู้ใช้ในระบบหรือไม่ 5.1 ใช่ ทำข้อ 6 5.2 ไม่ใช่ แสดงข้อความชื่อผู้ใช้หรือรหัสผ่านไม่ถูกต้อง แล้วกลับไปทำข้อ 2 6. ตรวจสอบความถูกต้องของรหัสผ่าน 6.1 ใช่ ทำข้อ 7 6.2 ไม่ใช่ แสดงข้อความชื่อผู้ใช้หรือรหัสผ่านไม่ถูกต้อง แล้วกลับไปทำข้อ 2 7. เข้าสู่ระบบและสร้างเซสชันสำหรับผู้ดูแลระบบ 8. แสดงข้อความเข้าสู่ระบบสำเร็จ 9. ส่งค่ากลับ

3.2.5.2) คำอธิบายกระบวนการ เพิ่มโมเดลที่ใช้ในการจำแนก

ชื่อกระบวนการ	เพิ่มโมเดลที่ใช้ในการจำแนก
วัตถุประสงค์	เพื่อนำเข้าไฟล์น้ำหนักโมเดล (.pth) และบันทึกข้อมูลรายละเอียดของโมเดลเข้าสู่ระบบ
ข้อมูลเข้า	ชื่อโมเดล, คำอธิบายโมเดล, ไฟล์โมเดล (.pth)
ข้อมูลออก	ข้อมูลโมเดลใหม่ที่ถูกบันทึกลงในระบบ
แฟ้มข้อมูล	models
ขั้นตอนการ ประมวลผล	1. แสดงหน้าเพิ่มโมเดลที่ใช้ในการจำแนก 2. ป้อนข้อมูลชื่อโมเดล และอัปโหลดไฟล์โมเดลเข้าสู่ระบบ 3. ตรวจสอบไฟล์ที่อัปโหลดเป็นนามสกุล .pth หรือไม่ 3.1 ใช่ ทำข้อ 4 3.2 ไม่ใช่ แสดงข้อความนามสกุลไม่ถูกต้อง แล้วไปทำข้อ 7 4. ตรวจสอบข้อมูลโมเดลซ้ำในฐานข้อมูลหรือไม่ 4.1 ใช่ แสดงข้อความโมเดลซ้ำในระบบ แล้วไปทำข้อ 7 4.2 ไม่ใช่ ทำข้อ 5 5. บันทึกไฟล์โมเดลลงสู่ระบบจัดเก็บโมเดล (webapp/model/) 6. บันทึกข้อมูลรายละเอียดโมเดลลงฐานข้อมูลตาราง models 7. แสดงข้อความผลการดำเนินงาน (สำเร็จ หรือ ข้อผิดพลาด) 8. ส่งค่ากลับ

3.2.5.3) คำอธิบายกระบวนการ ลบโมเดลที่ใช้ในการจำแนก

ชื่อกระบวนการ	ลบโมเดลที่ใช้ในการจำแนก
วัตถุประสงค์	เพื่อลบข้อมูลโมเดล ไฟล์น้ำหนักโมเดล และถอดโมเดลออกจากหน่วยความจำแคชของระบบ
ข้อมูลเข้า	รหัสคีย์โมเดลที่ต้องการลบ (model_key)
ข้อมูลออก	สถานะยืนยันการลบโมเดลสำเร็จ
แฟ้มข้อมูล	models
ขั้นตอนการประมวลผล	- เลือกโมเดลที่ต้องการลบ - ตรวจสอบยืนยันการลบโมเดลหรือไม่ - ใช่ ทำข้อ 3 - ไม่ใช่ แสดงข้อความยกเลิกการทำงาน แล้วไปทำข้อ 7 - ค้นหาข้อมูลโมเดลจากฐานข้อมูลตาราง models - ตรวจสอบพบโมเดลในฐานข้อมูลหรือไม่ - ใช่ ทำข้อ 5 - ไม่ใช่ แสดงข้อความไม่พบโมเดล แล้วไปทำข้อ 7 - ลบข้อมูลโมเดลออกจากฐานข้อมูลตาราง models - ลบไฟล์โมเดลออกจากระบบจัดเก็บ และถอดโมเดลออกจากหน่วยความจำแคช (MODELS.pop) - แสดงข้อความลบโมเดลสำเร็จ - ส่งค่ากลับ

3.2.5.4) คำอธิบายกระบวนการ กำหนดสถานะการใช้งานโมเดล

ชื่อกระบวนการ	กำหนดสถานะการใช้งานโมเดล
วัตถุประสงค์	เพื่อเปิดใช้งาน (Active) หรือปิดใช้งาน (Inactive) โมเดลจำแนก และบริหารจัดการหน่วยความจำแคช
ข้อมูลเข้า	รหัสคีย์โมเดลที่ต้องการสลับสถานะ (model_key)
ข้อมูลออก	สถานะการใช้งานใหม่ของโมเดล (is_active = 1 หรือ 0)
แฟ้มข้อมูล	models
ขั้นตอนการประมวลผล	1. เลือกโมเดลที่ต้องการสลับสถานะ 2. ค้นหาข้อมูลโมเดลจากฐานข้อมูลตาราง models 3. ตรวจสอบพบโมเดลในฐานข้อมูลหรือไม่ 3.1 ใช่ ทำข้อ 4 3.2 ไม่ใช่ แสดงข้อความไม่พบโมเดล แล้วไปทำข้อ 7 4. สลับสถานะการใช้งานและอัปเดตลงฐานข้อมูลตาราง models 5. ตรวจสอบว่าสถานะใหม่เป็นปิดใช้งาน (is_active = 0) หรือไม่ 5.1 ใช่ ถอดโมเดลออกจากหน่วยความจำแคช เพื่อคืนทรัพยากรระบบ 5.2 ไม่ใช่ กำหนดให้โมเดลพร้อมโหลดใช้งานตามความต้องการ (On-demand) 6. แสดงข้อความบันทึกสถานะสำเร็จ 7. ส่งค่ากลับ

3.2.5.5) คำอธิบายกระบวนการ จำแนกวิดีโอปลอม

ชื่อกระบวนการ	จำแนกวิดีโอปลอม
วัตถุประสงค์	เพื่อวิเคราะห์และจำแนกใบหน้าในวิดีโอว่าเป็นวิดีโอจริง (Real) หรือวิดีโอปลอมแปลงปลอม (Fake)
ข้อมูลเข้า	ไฟล์วิดีโอ (.mp4, .avi, .mov), รหัสโมเดลที่เลือกใช้งาน
ข้อมูลออก	ผลการจำแนก (Real / Fake), ค่าความเชื่อมั่น (Confidence), สัดส่วนเปอร์เซ็นต์ (Real % และ Fake %)
แฟ้มข้อมูล	models
ขั้นตอนการประมวลผล	1. รับไฟล์วิดีโอและโมเดลที่เลือกใช้งาน 2. สกัดเฟรมภาพจากวิดีโอตามช่วงเวลาและตรวจจับใบหน้าด้วย MTCNN 3. ตรวจสอบพบใบหน้าในวิดีโอหรือไม่ 3.1 ใช่ ทำข้อ 4 3.2 ไม่ใช่ แสดงข้อความไม่พบใบหน้า แล้วไปทำข้อ 8 4. ปรับขนาดภาพใบหน้าเป็น 299×299 พิกเซล และปรับค่าพิกเซลสู่ช่วงมาตรฐาน (Normalization) 5. ป้อนภาพเข้าสู่โมเดลโครงข่ายประสาทเทียม Xception เพื่อสกัดคุณลักษณะและคำนวณผลลัพธ์ 6. รวมผลลัพธ์และคำนวณค่าความน่าจะเป็นเฉลี่ย (Average Softmax Probability) 7. ตรวจสอบเงื่อนไขว่า ความน่าจะเป็นของคลาสปลอมแปลงมากกว่า 0.5 ($P(\text{Fake}) > 0.5$) หรือไม่ 7.1 ใช่ สรุปผลการจำแนกเป็นวิดีโอปลอมแปลง (Fake) และคำนวณค่าความเชื่อมั่น 7.2 ไม่ใช่ สรุปผลการจำแนกเป็นวิดีโอจริง (Real) และคำนวณค่าความเชื่อมั่น 8. ส่งค่ากลับ

3.2.5.6) คำอธิบายกระบวนการ แสดงผลการจำแนก

ชื่อกระบวนการ	แสดงผลการจำแนก
วัตถุประสงค์	เพื่อนำเสนอผลการวิเคราะห์วิดีโอแก่ผู้ใช้งาน และบันทึกประวัติการตรวจจับลงในระบบฐานข้อมูล
ข้อมูลเข้า	ผลการจำแนก (verdict), ค่าความเชื่อมั่น (confidence), สัดส่วนเปอร์เซ็นต์ (real_pct, fake_pct), ข้อมูลวิดีโอ (duration, resolution, analyzed_frames), ภาพตัวอย่าง (thumbnail)
ข้อมูลออก	หน้าจอแสดงผลการจำแนก, เรคอร์ดประวัติในฐานข้อมูล
แฟ้มข้อมูล	detection_logs
ขั้นตอนการประมวลผล	1. รับผลการจำแนกและข้อมูลรายละเอียดวิดีโอ 2. บันทึกภาพตัวอย่างใบหน้า (Thumbnail) ลงในระบบจัดเก็บไฟล์ภาพ 3. บันทึกข้อมูลประวัติการตรวจจับลงในฐานข้อมูลตาราง detection_logs 4. แสดงผลการจำแนก (Real / Fake) พร้อมแถบระดับความเชื่อมั่น (Confidence Bar) 5. แสดงข้อมูลรายละเอียดวิดีโอ (ความยาว, ความละเอียด, จำนวนเฟรมที่วิเคราะห์) 6. ส่งค่ากลับ

3.2.5.7) คำอธิบายกระบวนการ แบ่งส่วนชุดข้อมูล

ชื่อกระบวนการ	แบ่งส่วนชุดข้อมูล
วัตถุประสงค์	เพื่อจัดสรรและแบ่งชุดข้อมูลภาพใบหน้าจริงและปลอมออกเป็นชุดฝึกสอน (Training), ชุดตรวจสอบ (Validation) และชุดทดสอบ (Test) ตามสัดส่วนมาตรฐาน
ข้อมูลเข้า	รูปภาพใบหน้าทั้งหมดในแต่ละคลาส (Real, Fake)
ข้อมูลออก	รูปภาพของแต่ละคลาสที่ถูกแบ่งออกเป็น 3 ชุด ได้แก่ Train Set (70%), Validation Set (15%) และ Test Set (15%)
ขั้นตอนการประมวลผล	- กำหนดสัดส่วนการแบ่งชุดข้อมูล: $\text{num_train} = 0.70 \times \text{num_images}$ $\text{num_val} = 0.15 \times \text{num_images}$ $\text{num_test} = 0.15 \times \text{num_images}$ - นับจำนวนภาพทั้งหมดในแต่ละคลาส ($N = N_{\text{real}} + N_{\text{fake}}$) - สุ่มสลับลำดับภาพทั้งหมด (Random Shuffle) เพื่อลดอคติในการจัดกลุ่ม - แบ่งภาพตามสัดส่วนที่คำนวณได้ไปยังโฟลเดอร์ train/, val/ และ test/ - ตรวจสอบความถูกต้องและนับจำนวนภาพในแต่ละชุดข้อมูล - แสดงผลสรุปจำนวนภาพในแต่ละชุดข้อมูล - ส่งค่ากลับ

3.2.5.8) คำอธิบายกระบวนการ ฝึกฝนโมเดล Xception

ชื่อกระบวนการ	ฝึกฝนโมเดล Xception
วัตถุประสงค์	เพื่อปรับค่าน้ำหนักโครงข่าย Xception ด้วยชุดข้อมูลฝึกสอน และ ประเมินผลในแต่ละรอบเพื่อบันทึกโมเดลที่มีความแม่นยำสูงสุด
ข้อมูลเข้า	ชุดข้อมูล Train Set, Validation Set, พารามิเตอร์การฝึกสอน (Batch size, Learning rate, Epochs)
ข้อมูลออก	ไฟล์น้ำหนักโมเดลที่ดีที่สุด (.pth), ประวัติค่า Loss และ Accuracy
ขั้นตอนการประมวลผล	- กำหนดโครงสร้างสถาปัตยกรรม Xception และกำหนดค่าพารามิเตอร์เริ่มต้น: - epochs = <i>NUM_EPOCHS</i> - optimizer = Adam(lr = 0.0001) - loss_function = Cross-Entropy Loss - กำหนดรอบเริ่มต้น: $i = 0$ - ตรวจสอบเงื่อนไขว่า $i < \text{epochs}$ หรือไม่ - ใช่ ทำข้อ 4 - ไม่ใช่ ไปทำข้อ 8 - ทำการฝึกสอน (Training Phase): - ป้อนข้อมูล Train Batch ผ่านโมเดล (Forward Pass) - คำนวณค่าสูญเสีย: $\mathcal{L}_{\text{train}} = \text{CrossEntropy}(y_{\text{pred}}, y_{\text{true}})$ - คำนวณเกรเดียนต์และปรับปรุงค่าน้ำหนัก: $\theta = \theta - \eta \nabla_{\theta} \mathcal{L}_{\text{train}}$ - ทำการประเมินผล (Validation Phase): - ป้อนข้อมูล Validation Set ผ่านโมเดลโดยปิดการคำนวณเกรเดียนต์ (torch.no_grad()) - คำนวณค่าสูญเสีย $\mathcal{L}_{\text{val}}$ และความแม่นยำ Acc_{val} - ตรวจสอบว่าได้ค่าสูญเสียต่ำสุดใหม่หรือไม่ ($\mathcal{L}_{\text{val}} < \text{best_loss}$) - ใช่ บันทึกค่าน้ำหนักโมเดลที่ดีที่สุดลงไฟล์ .pth - ไม่ใช่ คงไฟล์น้ำหนักเดิมไว้

	7. เพิ่มค่ารอบ $i = i + 1$ แล้วกลับไปทำข้อ 3 8. ส่งค่ากลับ
--	---

3.2.5.9) คำอธิบายกระบวนการ ทดสอบโมเดล

ชื่อกระบวนการ	ทดสอบโมเดล
วัตถุประสงค์	เพื่อวัดประสิทธิภาพเชิงปริมาณของโมเดลที่ผ่านการฝึกฝนแล้ว ด้วยชุดข้อมูลทดสอบที่ไม่เคยนำมาใช้ฝึกฝนมาก่อน
ข้อมูลเข้า	ไฟล์โมเดลที่ฝึกฝนแล้ว (.pth), ข้อมูลภาพชุดทดสอบ (Test Set)
ข้อมูลออก	ตาราง Confusion Matrix, ค่า Accuracy, Precision, Recall, F1-Score
ขั้นตอนการประมวลผล	- โหลดไฟล์โมเดลที่ผ่านการฝึกฝนแล้วเข้าสู่หน่วยความจำ - โหลดชุดข้อมูลทดสอบ (Test Set) - ป้อนภาพใน Test Set ทั้งหมดเข้าสู่โมเดลเพื่อทำนายผลลัพธ์ ($y_{pred} = \text{argmax}(\text{model}(x))$) - สร้างตารางความสับสน (Confusion Matrix) เปรียบเทียบผลทำนายกับผลจริง เพื่อหาค่า TP, TN, FP, FN - คำนวณค่าชี้วัดประสิทธิภาพตามสมการมาตรฐาน: - $Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$ - $Precision = \frac{TP}{TP+FP}$ - $Recall = \frac{TP}{TP+FN}$ - $F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$ - แสดงผลลัพธ์ตาราง Confusion Matrix และค่าชี้วัดประสิทธิภาพทั้งหมด - ส่งค่ากลับ

3.2.5.10) คำอธิบายกระบวนการ แสดงสถิติภาพรวม

ชื่อกระบวนการ	แสดงสถิติภาพรวม
วัตถุประสงค์	เพื่อรวบรวม คำนวณ และแสดงข้อมูลสถิติภาพรวมการตรวจจับวิดีโอที่แปลกในระบบสำหรับผู้ดูแลระบบ
ข้อมูลเข้า	คำร้องขอแสดงผลสถิติจากผู้ดูแลระบบ
ข้อมูลออก	ข้อมูลการ์ดสถิติภาพรวม, แผนภูมิและกราฟสรุปสัดส่วน
แฟ้มข้อมูล	detection_logs, admins
ขั้นตอนการประมวลผล	- ตรวจสอบสิทธิ์ผู้ดูแลระบบผ่านการตรวจสอบสิทธิ์หรือไม่ - ใช่ ทำข้อ 2 - ไม่ใช่ แสดงหน้าเข้าสู่ระบบ แล้วไปทำข้อ 6 - ดึงข้อมูลประวัติการตรวจจับทั้งหมดจากฐานข้อมูลตาราง detection_logs - คำนวณสถิติภาพรวม: - จำนวนวิดีโอทั้งหมด (N_{total}) - จำนวนวิดีโอจริง (N_{real}) และวิดีโอปลอม (N_{fake}) - สัดส่วนร้อยละวิดีโอปลอม ($\%Fake = \frac{N_{fake}}{N_{total}} \times 100$) - ค่าความเชื่อมั่นเฉลี่ย และแนวโน้มสถิติรายวัน - แสดงการ์ดสรุปตัวเลขสถิติภาพรวม - แสดงผลแผนภูมิและกราฟสรุปสัดส่วน - ส่งค่ากลับ

3.2.5.11) คำอธิบายกระบวนการ แสดงประวัติการตรวจจับ

ชื่อกระบวนการ	แสดงประวัติการตรวจจับ
วัตถุประสงค์	เพื่อค้นหา กรอง และแสดงผลตารางรายการประวัติการตรวจจับวิดีโอย้อนหลัง
ข้อมูลเข้า	พารามิเตอร์ตัวกรองผลลัพธ์ (Filter), จำนวนแถวข้อมูล (Limit), หน้าข้อมูล (Pagination)
ข้อมูลออก	ตารางรายการประวัติการตรวจจับย้อนหลัง
แฟ้มข้อมูล	detection_logs, admins
ขั้นตอนการประมวลผล	- ตรวจสอบสิทธิ์ผู้ดูแลระบบผ่านการตรวจสอบสิทธิ์หรือไม่ - ใช่ ทำข้อ 2 - ไม่ใช่ แสดงหน้าเข้าสู่ระบบ แล้วไปทำข้อ 6 - กำหนดพารามิเตอร์การแสดงผล (จำนวนแถวและตัวกรองสถานะผลลัพธ์) - ดึงข้อมูลประวัติการตรวจจับจากฐานข้อมูลตาราง detection_logs ตามพารามิเตอร์ - จัดเรียงข้อมูลตามวันเวลาจากล่าสุดไปหาอดีต (ORDER BY timestamp DESC) - แสดงผลตารางประวัติการตรวจจับ พร้อมชื่อไฟล์ ผลการจำแนก ค่าความเชื่อมั่น และภาพตัวอย่าง - ส่งค่ากลับ

3.2.5.12) คำอธิบายกระบวนการ การตรวจจับและสกัดใบหน้าด้วย MTCNN

ชื่อกระบวนการ	การตรวจจับและสกัดใบหน้าด้วย MTCNN
วัตถุประสงค์	เพื่อตรวจหาตำแหน่งใบหน้าในเฟรมวิดีโอและครอบตัดเฉพาะบริเวณใบหน้า พร้อมปรับขนาดเข้าสู่โมเดลจำแนก
ข้อมูลเข้า	เฟรมภาพจากวิดีโอ (RGB Frame ขนาด $H \times W \times 3$)
ข้อมูลออก	ภาพใบหน้าที่ถูกครอบตัดและปรับขนาดแล้ว (Cropped Face Image ขนาด $299 \times 299 \times 3$)
ขั้นตอนการประมวลผล	1. รับเฟรมภาพวิดีโอเข้าสู่โมเดล MTCNN (Proposal Net, Refine Net, Output Net) 2. ค้นหากรอบพิกัดใบหน้า (Bounding Box: $[x_1, y_1, x_2, y_2]$) และจุดสำคัญบนใบหน้า (Facial Landmarks) 3. ตรวจสอบพบใบหน้าที่มีค่าความเชื่อมั่นผ่านเกณฑ์หรือไม่ 3.1 ใช่ ทำข้อ 4 3.2 ไม่ใช่ ส่งค่าไม่พบใบหน้า แล้วไปทำข้อ 6 4. เพิ่มระยะขอบรอบใบหน้า (Margin = 40 พิกเซล) 5. ครอบตัดภาพใบหน้าและปรับขนาดเป็น 299×299 พิกเซล 6. ส่งค่ากลับ

3.2.5.13) คำอธิบายกระบวนการ คอนโวลูชันแบบแยกส่วนตามแนวลึก (Depthwise Separable Convolution)

ชื่อกระบวนการ	Depthwise Separable Convolution
วัตถุประสงค์	เพื่อสกัดคุณลักษณะของภาพโดยลดจำนวนพารามิเตอร์และการคำนวณผ่านการแยกการประมวลผลเป็น Depthwise และ Pointwise Convolution ตามสถาปัตยกรรม Xception
ข้อมูลเข้า	Feature Map อินพุต ขนาด $H \times W \times C_{in}$
ข้อมูลออก	Feature Map เอาต์พุต ขนาด $H' \times W' \times C_{out}$
ขั้นตอนการประมวลผล	1. รับอินพุต Feature Map ขนาด $H \times W \times C_{in}$ 2. ทำ Depthwise Convolution: ใช้ฟิลเตอร์ขนาด 3×3 คอนโวลูชันแยกทีละ Channel เพื่อสกัดคุณลักษณะเชิงพื้นที่ 3. ทำ Pointwise Convolution: ใช้ฟิลเตอร์ขนาด 1×1 รวมข้อมูลข้าม Channel เพื่อปรับขนาดเป็น C_{out} 4. ส่งผลลัพธ์ผ่าน Batch Normalization 5. ส่งค่ากลับ

3.2.5.14) คำอธิบายกระบวนการ ฟังก์ชันกระตุ้น ReLU (Activation Function - ReLU)

ชื่อกระบวนการ	Activation Function (ReLU)
วัตถุประสงค์	เพื่อเพิ่มคุณสมบัติการไม่เป็นเชิงเส้น (Non-linearity) ให้กับโครงข่ายประสาทเทียม โดยเปลี่ยนค่าที่เป็นลบทั้งหมดให้เป็นศูนย์ และคงค่าบวกไว้ตามเดิม
ข้อมูลเข้า	ค่า Feature Map อินพุต (z)
ข้อมูลออก	ค่า Feature Map เอาต์พุต (a)
ขั้นตอนการประมวลผล	- รับค่าอินพุต z - ตรวจสอบเงื่อนไขว่า $z > 0$ หรือไม่ - ใช่ กำหนดให้ $a = z$ (คงค่าเดิม) - ไม่ใช่ กำหนดให้ $a = 0$ (ตัดค่าลบเป็นศูนย์) - ผลลัพธ์คือ Feature Map ใหม่ที่มีค่าเท่ากับ a - ส่งค่ากลับ

3.2.5.15) คำอธิบายกระบวนการ การรวมข้อมูลเฉลี่ยระดับโลก (Global Average Pooling)

ชื่อกระบวนการ	Global Average Pooling
วัตถุประสงค์	เพื่อลดมิติเชิงพื้นที่ของ Feature Map ให้กลายเป็นเวกเตอร์ 1 มิติ โดยหาค่าเฉลี่ยของแต่ละ Channel ก่อนส่งเข้าสู่ชั้นจำแนก
ข้อมูลเข้า	Feature Map ขนาด $H \times W \times C$
ข้อมูลออก	เวกเตอร์คุณลักษณะขนาด $1 \times C$
ขั้นตอนการประมวลผล	- รับ Feature Map ขนาด $H \times W \times C$ - คำนวณค่าเฉลี่ยของแต่ละ Channel C ตามสูตร: $v[c] = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W \text{FeatureMap}[i, j, c]$ - รวมค่าเฉลี่ยทั้งหมดเป็นเวกเตอร์ v ขนาด C มิติ - ส่งค่ากลับ

3.2.5.16) คำอธิบายกระบวนการ ชั้นเชื่อมต่อเต็มรูปแบบ (Fully Connected Layer)

ชื่อกระบวนการ	Fully Connected Layer
วัตถุประสงค์	เพื่อคำนวณผลรวมเชิงเส้นถ่วงน้ำหนักจากเวกเตอร์คุณลักษณะ และสร้างคะแนนลอจิต (Logits) สำหรับแต่ละคลาส
ข้อมูลเข้า	เวกเตอร์คุณลักษณะอินพุต x ขนาด C มิติ
ข้อมูลออก	เวกเตอร์ลอจิต (Logits) $z = [z_{\text{real}}, z_{\text{fake}}]$
ขั้นตอนการประมวลผล	- รับเวกเตอร์คุณลักษณะ x - คำนวณผลรวมเชิงเส้นตามค่าน้ำหนัก (W) และค่าไบแอส (b): $z = W \cdot x + b$ - ผลลัพธ์ที่ได้คือคะแนนดิบสำหรับคลาส Real (z_{real}) และคลาส Fake (z_{fake}) - ส่งค่ากลับ

3.2.5.17) คำอธิบายกระบวนการ ฟังก์ชันซอฟต์แมกซ์ (Softmax Function)

ชื่อกระบวนการ	Softmax Function
วัตถุประสงค์	เพื่อแปลงค่าคะแนนดิบ (Logits) ให้กลายเป็นค่าความน่าจะเป็น (Probability) ของแต่ละคลาส โดยผลรวมของความน่าจะเป็นเท่ากับ 1.0 (100%)
ข้อมูลเข้า	ค่าคะแนนดิบ $z = [z_{\text{real}}, z_{\text{fake}}]$
ข้อมูลออก	เวกเตอร์ความน่าจะเป็น $P = [P(\text{Real}), P(\text{Fake})]$
ขั้นตอนการประมวลผล	- รับค่าอินพุต $z = [z_{\text{real}}, z_{\text{fake}}]$ - คำนวณค่าเลขชี้กำลังของแต่ละคลาส: $e_{\text{real}} = \exp(z_{\text{real}}), e_{\text{fake}} = \exp(z_{\text{fake}})$ - คำนวณผลรวมของค่าเลขชี้กำลังทั้งหมด: $\text{sum_exp} = e_{\text{real}} + e_{\text{fake}}$ - คำนวณค่าความน่าจะเป็นของแต่ละคลาส: $P(\text{Real}) = \frac{e_{\text{real}}}{\text{sum_exp}}, P(\text{Fake}) = \frac{e_{\text{fake}}}{\text{sum_exp}}$ - ส่งค่ากลับ

3.2.5.18) คำอธิบายกระบวนการ การหาคลาสค่าสูงสุด (Argmax Decision)

ชื่อกระบวนการ	Argmax Decision
วัตถุประสงค์	เพื่อเปรียบเทียบค่าความน่าจะเป็นและตัดสินใจเลือกคลาสที่ได้ค่าความน่าจะเป็นสูงสุดเป็นผลลัพธ์การทำนายขั้นสุดท้าย
ข้อมูลเข้า	เวกเตอร์ความน่าจะเป็น $P = [P_{(Real)}P_{(Fake)}]$
ข้อมูลออก	ผลการทำนายคลาส (Predicted Class: Real หรือ Fake) และค่าความเชื่อมั่น (Confidence)
ขั้นตอนการประมวลผล	- รับค่าความน่าจะเป็น $P = [P_{(Real)}P_{(Fake)}]$ - ตรวจสอบเงื่อนไขว่า $P_{(Fake)} > P_{(Real)}$ หรือไม่ - ใช่ กำหนดผลลัพธ์เป็น "Fake" (วิดีโอปลอม) และค่าความเชื่อมั่นเท่ากับ $P_{(Fake)} \times 100\%$ - ไม่ใช่ กำหนดผลลัพธ์เป็น "Real" (วิดีโอจริง) และค่าความเชื่อมั่นเท่ากับ $P_{(Real)} \times 100\%$ - ส่งค่ากลับ

3.2.6 พจนานุกรมข้อมูล (Data Dictionary) ถ้ามี

ตารางที่ 3.1 พจนานุกรมข้อมูล

Table name	Attribute name	Description	Data type	Size	Key
admins	id	รหัสประจำตัวผู้ดูแลระบบ (ลำดับอัตโนมัติ)	Int		PK
	username	ชื่อบัญชีผู้ใช้สำหรับเข้าสู่ระบบ	Varchar	50	
	password	รหัสผ่านสำหรับเข้าสู่ระบบ	Varchar	255	
	role	บทบาทหรือระดับสิทธิ์การใช้งานระบบ	Varchar	20	
	created_at	วันที่และเวลาที่สร้างบัญชีผู้ใช้	Datetime		
models	id	รหัสประจำตัวโมเดล ปัญญาประดิษฐ์	Int		PK
	key	รหัสคีย์อ้างอิงเฉพาะของโมเดล	Varchar	50	
	name	ชื่อโมเดลที่ใช้แสดงผลในระบบ	Varchar	100	
	filename	ชื่อไฟล์น้ำหนักโมเดล (.pth) ในระบบจัดเก็บ	Varchar	255	
	description	รายละเอียดหรือคำอธิบายโมเดล	Text		
	is_active	สถานะการเปิด/ปิดใช้งานโมเดล (1=เปิด, 0=ปิด)	Tinyint	1	
	created_at	วันที่และเวลาที่นำเข้าโมเดลสู่ระบบ	Datetime		
detection_logs	id	รหัสประจำตัวประวัติการตรวจจับ	Int		PK
	filename	ชื่อไฟล์วิดีโอที่นำเข้ามาตรวจจับ	Varchar	255	
	is_fake	สถานะผลการจำแนก (1=วิดีโอปลอม, 0=วิดีโอจริง)	Tinyint	1	
	verdict	ข้อความสรุปผลการวินิจฉัย	Varchar	50	

Table name	Attribute name	Description	Data type	Size	Key
	confidence	ค่าระดับความเชื่อมั่นในการจำแนก (ร้อยละ)	Float		
	real_pct	สัดส่วนความน่าจะเป็นวิดีโอจริง (ร้อยละ)	Float		
	fake_pct	สัดส่วนความน่าจะเป็นวิดีโอปลอม (ร้อยละ)	Float		
	duration	ระยะเวลาความยาวของคลิปวิดีโอ	Varchar	20	
	resolution	ขนาดความละเอียดของภาพวิดีโอ	Varchar	20	
	analyzed_frames	จำนวนเฟรมภาพใบหน้าที่นำมาวิเคราะห์	Int		
	timestamp	วันที่และเวลาที่บันทึกผลการตรวจจับ	Datetime		

3.2.7 การออกแบบส่วนต่อประสานกับผู้ใช้ (User Interface Design)

ระบบตรวจจับวิดีโอติปเฟกใบหน้า

หน้าตรวจจับ

ผู้ดูแลระบบ

ระบบตรวจจับวิดีโอติปเฟกใบหน้าด้วยปัญญาประดิษฐ์

อัปโหลดวิดีโอ

เลือกหรือลากไฟล์วิดีโอมาวางที่นี่

เลือกไฟล์

ตรวจสอบวิดีโอ

ผลการวิเคราะห์

ยังไม่มีผลการวิเคราะห์

รูปที่ 3.15 หน้าจอหลักและอัปโหลดวิดีโอ

ระบบตรวจจับวิดีโอติปเฟกใบหน้า

หน้าตรวจจับ

ผู้ดูแลระบบ

ผลการจำแนกวิดีโอติปเฟก

วิดีโอที่ตรวจสอบ

[วิดีโอ: xxxx.mp4]

รายละเอียดวิดีโอ:

- ความยาว: xxxx
- ความละเอียด: xxxx
- จำนวนเฟรมที่วิเคราะห์: xxxx

ผลการวิเคราะห์

ผลการจำแนก: xxxx

ค่าความเชื่อมั่น: xxxx %

วิดีโอจริง: xxxx % วิดีโอปลอม: xxxx %

ผลการจำแนกแยกตามโมเดล:

โมเดล	ผลลัพธ์	ความน่าจะเป็น
xxxx	xxxx	xxxx %
xxxx	xxxx	xxxx %

ตรวจสอบวิดีโอใหม่

รูปที่ 3.16 หน้าจอแสดงผลการจำแนกวิดีโอติปเฟก

ระบบตรวจจับวิธีโอติปเฟกใบหน้า

หน้าตรวจจับ

ผู้ดูแลระบบ

เข้าสู่ระบบผู้ดูแลระบบ

ชื่อผู้ใช้

xxxx

รหัสผ่าน

xxxx

เข้าสู่ระบบ

รูปที่ 3.17 หน้าจอเข้าสู่ระบบผู้ดูแล

ระบบตรวจจับวิธีโอติปเฟกใบหน้า

หน้าตรวจจับ

แผงควบคุม

ออก

ภาพรวมสถิติระบบ

การอัปโหลดทั้งหมด

xxxx

วิธีโอจริง

xxxx (xxxx %)

วิธีโอปลอมแปลง

xxxx (xxxx %)

โมเดลที่เปิดใช้งาน

xxxx

สัดส่วนผลการจำแนก

วิธีโอจริง: xxxx %

วิธีโอปลอมแปลง: xxxx %

สถิติการใช้งานย้อนหลัง

วันที่	จำนวนอัปโหลด	วิธีโอจริง	ปลอม
xxxx	xxxx	xxxx	xxxx
xxxx	xxxx	xxxx	xxxx
xxxx	xxxx	xxxx	xxxx
xxxx	xxxx	xxxx	xxxx

รูปที่ 3.18 หน้าจอภาพรวมสถิติผู้ดูแลระบบ

ระบบตรวจจับวิดีโอติปเฟกใบหน้า

หน้าตรวจจับ

แผงควบคุม

ออก

จัดการโมเดลที่ใช้ในการจำแนก

+ เพิ่มโมเดล

ลำดับ	ชื่อโมเดล	ไฟล์โมเดล (.pth)	สถานะการใช้งาน	การจัดการ
1	xxxx	xxxx.pth	เปิดใช้งาน	ลบ
2	xxxx	xxxx.pth	เปิดใช้งาน	ลบ
3	xxxx	xxxx.pth	ปิดใช้งาน	ลบ
4	xxxx	xxxx.pth	เปิดใช้งาน	ลบ

รูปที่ 3.19 หน้าจอจัดการโมเดล AI

ระบบตรวจจับวิดีโอติปเฟกใบหน้า

หน้าตรวจจับ

แผงควบคุม

ออก

เพิ่มโมเดลที่ใช้ในการจำแนก

รหัสโมเดล (Model Key)

xxxx

ชื่อโมเดล

xxxx

ไฟล์โมเดล (.pth)

xxxx.pth

ยกเลิก

บันทึก

รูปที่ 3.20 หน้าจอเพิ่มโมเดล AI ใหม่

ระบบตรวจจับวิดีโอติปเฟกใบหน้า

หน้าตรวจจับ

แผงควบคุม

ออก

ยืนยันการลบโมเดล

คุณต้องการลบโมเดล xxxx หรือไม่?

ยกเลิก

ยืนยัน

รูปที่ 3.21 หน้าจอยืนยันการลบโมเดล AI

ระบบตรวจจับวิดีโอติปเฟกใบหน้า

หน้าตรวจจับ

แผงควบคุม

ออก

ประวัติการตรวจจับวิดีโอย้อนหลัง

ค้นหา: xxxx

ทั้งหมด

วิดีโอจริง

วิดีโอปลอม

ลำดับ	ชื่อไฟล์	ผลการจำแนก	ความเชื่อมั่น	ความยาว	วันที่และเวลา
1	xxxx.mp4	xxxx	xxxx %	xxxx	xxxx
2	xxxx.mp4	xxxx	xxxx %	xxxx	xxxx
3	xxxx.mp4	xxxx	xxxx %	xxxx	xxxx
4	xxxx.mp4	xxxx	xxxx %	xxxx	xxxx
5	xxxx.mp4	xxxx	xxxx %	xxxx	xxxx

หน้า 1 จาก xxxx

ก่อนหน้า

ถัดไป

รูปที่ 3.22 หน้าจอประวัติการตรวจจับวิดีโอย้อนหลัง

เอกสารอ้างอิง

- [1] Coding Dude, “Deepfake AI face swap,” Medium. Accessed: Sep. 10, 2026. [Online]. Available: <https://medium.com/@codingdudecom/deepfake-ai-face-swap-e11edc7d67e1>
- [2] T. Walczyna and Z. Piotrowski, “Quick overview of face swap deep fakes,” Applied Sciences, vol. 13, no. 11, Art. no. 6711, 2023, doi: 10.3390/app13116711. [Online]. Available: <https://www.mdpi.com/2076-3417/13/11/6711>
- [3] O. von Voss, “Face2Face: Real-time face capture and reenactment of videos,” CineD, Apr. 9, 2016. Accessed: Sep. 10, 2026. [Online]. Available: <https://www.cined.com/face2face-real-time-face-capture-and-reenactment-of-videos/>
- [4] A. Maher, “Understanding FaceShifter: A new face-swapping model,” Medium, Apr. 9, 2020. Accessed: Sep. 10, 2026. [Online]. Available: <https://medium.com/data-science/understanding-faceshifter-a-new-face-swapping-model-983b81a9d37d>
- [5] J. Thies, M. Zollhöfer, and M. Nießner, “Deferred neural rendering: Image synthesis using neural textures,” ACM Trans. Graph., vol. 38, no. 4, Art. no. 66, pp. 66:1–66:12, 2019, doi: 10.1145/3306346.3323035. [Online]. Available: <https://niessnerlab.org/projects/thies2019neural.html>
- [6] “Baseline DeepFake detection pipeline,” ResearchGate. Accessed: Sep. 10, 2026. [Online]. Available: https://www.researchgate.net/figure/Baseline-DeepFake-detection-pipeline_fig2_342169482
- [7] D. S. Ma, J. Correll, and B. Wittenbrink, “The Chicago face database: A free stimulus set of faces and norming data,” Behav. Res. Methods, vol. 47, pp. 1122–1135, 2015, doi: 10.3758/s13428-014-0532-5. [Online]. Available: <https://link.springer.com/article/10.3758/s13428-014-0532-5>
- [8] V. Minaphinat, “Machine Learning คืออะไร?,” Medium, Feb. 28, 2018. Accessed: Sep. 10, 2026. [Online]. Available: <https://medium.com/investic/machine-learning-คืออะไร-fa8bf6663c07>

- [9] GeeksforGeeks, "Architecture and learning process in neural network," May 13, 2026. Accessed: Sep. 10, 2026. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/ml-architecture-and-learning-process-in-neural-network/>
- [10] NECTEC, "Machine Learning," National Electronics and Computer Technology Center. Accessed: Sep. 10, 2026. [Online]. Available: <https://www.nectec.or.th/news/news-public-document/machine-learningmanufact-1.html>
- [11] A. Zhang, Z. C. Lipton, M. Li, and A. J. Smola, "Multiple input and multiple output channels," in Dive into Deep Learning. Accessed: Sep. 10, 2026. [Online]. Available: https://d2l.ai/chapter_convolutional-neural-networks/channels.html
- [12] SuperDataScience Team, "Convolutional neural networks (CNN): Step 3 – Flattening," SuperDataScience, Aug. 18, 2018. Accessed: Sep. 10, 2026. [Online]. Available: <https://www.superdatascience.com/blogs/convolutional-neural-networks-cnn-step-3-flattening>
- [13] Viso, "Xception model: Analyzing depthwise separable convolutions," Viso AI. Accessed: Sep. 10, 2026. [Online]. Available: <https://viso.ai/deep-learning/xception-model/>
- [14] ResearchGate, "Standard Xception architecture," ResearchGate. Accessed: Sep. 10, 2026. [Online]. Available: https://www.researchgate.net/figure/Standard-Xception-architecture_fig4_366581421
- [15] MTCNN Documentation, "Introduction," MTCNN Documentation. Accessed: Sep. 10, 2026. [Online]. Available: <https://mtcnn.readthedocs.io/en/latest/introduction/>
- [16] HarmoniaLeo, "Face-Recognizer," GitHub repository. Accessed: Sep. 10, 2026. [Online]. Available: <https://github.com/HarmoniaLeo/Face-Recognizer>
- [17] P. Gatchalee, "Confusion Matrix Machine Learning," Medium. Accessed: Sep. 10, 2026. [Online]. Available: <https://medium.com/@pagongatchalee/confusion-matrixmachine-learning>

- [18] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao, "Joint face detection and alignment using multitask cascaded convolutional networks," *IEEE Signal Process. Lett.*, vol. 23, no. 10, pp. 1499–1503, Oct. 2016, doi: 10.1109/LSP.2016.2603342. [Online]. Available: <https://arxiv.org/abs/1604.02878>
- [19] A. Rössler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies, and M. Nießner, "FaceForensics++: Learning to detect manipulated facial images," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2019, pp. 1–11, doi: 10.1109/ICCV.2019.00009. [Online]. Available: <https://arxiv.org/abs/1901.08971>
- [20] F. Chollet, "Xception: Deep learning with depthwise separable convolutions," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 1251–1258. [Online]. Available: <https://arxiv.org/abs/1610.02357>
- [21] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. Int. Conf. Machine Learning (ICML)*, 2019. [Online]. Available: <https://arxiv.org/abs/1905.11946>
- [22] S. A. Khan and D.-T. Dang-Nguyen, "Hybrid transformer network for deepfake detection," in *Proc. 19th Int. Conf. Content-based Multimedia Indexing (CBMI)*, 2022, pp. 8–14, doi: 10.1145/3549555.3549588. [Online]. Available: <https://arxiv.org/abs/2208.05820>
- [23] N. Bharati, P. Wong, S. Kouadri Mostéfaoui, D. Kbaier, and J. Collie, "Explainable deepfake detection: A multi-model framework with human-interpretable rationales for legal investigation purposes," *Machine Learning with Applications*, vol. 23, Art. no. 100819, 2026. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2666827025002026>
- [24] B. Pinhasov, R. Lapid, R. Ohayon, M. Sipper, and Y. Aperstein, "XAI-based detection of adversarial attacks on deepfake detectors," *Transactions on Machine Learning Research*, 2024. [Online]. Available: <https://arxiv.org/abs/2403.02955>

- [25] L. Kanya Kumari, P. M, D. R. M, G. D. D, and S. B, "Deepfake detection in images & videos using XceptionNet: A deep learning approach," International Journal of Advanced Research in Computer and Communication Engineering, vol. 14, no. 3, 2025, doi: 10.17148/IJARCCCE.2025.14356. [Online]. Available: <https://ijarcce.com/papers/deepfake-detection-in-images-videos-usingxceptionnet-a-deep-learning-approach/>
- [26] HongguLiu, "Deepfake-Detection: The PyTorch implementation of deepfake detection based on FaceForensics++," GitHub repository. [Online]. Available: <https://github.com/HongguLiu/Deepfake-Detection>
- [27] U. Joshi, "Age-diverse deepfake dataset: Bridging the age gap in deepfake detection," arXiv preprint arXiv:2508.06552, Aug. 2025. [Online]. Available: <https://arxiv.org/abs/2508.06552>
- [28] S. Sandeep Kumar, Yogesh, P. L, et al., "Explainable deepfake detection: Integrating Grad-CAM with CNN-RNN architecture for real-time forensic analysis," TechRxiv, Dec. 2025, doi: 10.36227/techrxiv.176471850.05490312/v1. [Online]. Available: <https://www.techrxiv.org/doi/10.36227/techrxiv.176471850.05490312>
- [29] S. Tariq, P. Singh, S. S. Woo, I. Irmalasari, S. Gupta, and D. Gupta, "From prediction to explanation: Multimodal, explainable, and interactive deepfake detection framework for non-expert users," arXiv preprint arXiv:2508.07596, Aug. 2025. [Online]. Available: <https://arxiv.org/abs/2508.07596>
- [30] K. Lipianina-Honcharenko, M. Telka, and N. Melnyk, "Comparison of ResNet, EfficientNet, and Xception architectures for deepfake detection," in Proc. AdvAIT-2024: 1st Int. Workshop on Advanced Applied Information Technologies, Khmelnytskyi, Ukraine–Zilina, Slovakia, Dec. 2024. [Online]. Available: <https://ceur-ws.org/Vol-3899/paper3.pdf>
- [31] P. Korshunov and S. Marcel, "Deepfake detection: Humans vs. machines," arXiv preprint arXiv:2009.03155, Sep. 2020. [Online]. Available: <https://arxiv.org/abs/2009.03155>

- [32] V. L. L. Thing, “Deepfake detection with deep learning: Convolutional neural networks versus transformers,” arXiv preprint arXiv:2304.03698, 2023. [Online]. Available: <https://arxiv.org/abs/2304.03698>
- [33] Z. Yan, Y. Zhang, X. Yuan, S. Lyu, and B. Wu, “DeepfakeBench: A comprehensive benchmark of deepfake detection,” in Proc. 37th Conf. Neural Information Processing Systems (NeurIPS 2023) Datasets and Benchmarks Track, 2023. [Online]. Available: <https://arxiv.org/abs/2307.01426>